МАТЕМАТИЧЕСКОЕ И ПРОГРАММНОЕ ОБЕСПЕЧЕНИЕ ВЫЧИСЛИТЕЛЬНЫХ СИСТЕМ, КОМПЛЕКСОВ И КОМПЬЮТЕРНЫХ СЕТЕЙ

MATHEMATICAL AND SOFTWARE OF COMPUTERS, COMPLEXES AND COMPUTER NETWORKS

2.3.5 *МАТЕМАТИЧЕСКОЕ И ПРОГРАММНОЕ ОБЕСПЕЧЕНИЕ ВЫЧИСЛИТЕЛЬНЫХ СИСТЕМ, КОМПЛЕКСОВ И КОМПЬЮТЕРНЫХ СЕТЕЙ (ТЕХНИЧЕСКИЕ, ФИЗИКО-МАТЕМАТИЧЕСКИЕ НАУКИ)*

MATHEMATICAL AND SOFTWARE OF COMPUTERS, COMPLEXES AND COMPUTER NETWORKS

DOI: 10.33693/2313-223X-2024-11-2-58-85

УДК: 004.023

ГРНТИ: 50.41

EDN: MRWGYA

Модификация квантово-инспирированного генетического алгоритма численной оптимизации с использованием кудита в условиях имитации квантовой декогеренции

В.В. Масленников[a] ©, Л.А. Демидова[b] ©

МИРЭА – Российский технологический университет, г. Москва, Российская Федерация

[a] **E-mail:** vldmsn@yahoo.com

[b] **E-mail:** liliya.demidova@rambler.ru

Аннотация. Генетический алгоритм численной оптимизации (GA) метаэвристического класса представляет собой метод поиска оптимальных решений, основанный на биологических принципах естественного отбора и изменчивости. GA характеризуется высокой скоростью работы, устойчивостью к шуму в данных, низкой вероятностью попадания в локальный экстремум мультимодальной целевой функции, а также одновременным применением вероятностных и детерминированных правил для порождения точек поискового пространства. Альтернативой классического GA является квантово-инспирированный генетический алгоритм численной оптимизации (QIGA), обладающий преимуществами, которые недостижимы для GA, за счет использования концепций и принципов квантовых вычислений. В статье предлагается новый подход к реализации квантово-инспирированного генетического алгоритма численной оптимизации для поиска глобального максимума целевой функции, основывающийся на моделировании функционирования GA имитацией выполнения квантовых вычислений на базе кудита в условиях существования квантовой декогеренции эпохи зашумленных квантовых алгоритмов среднего масштаба. С этой целью для осуществления квантовых операций вращения состояний многоуровневых квантовых систем в работе представлена матрица плотности на основе операторов Гейзенберга–Вейля как аналог сферы Блоха для кудитов. Имитация квантовой декогеренции интерпретируется с точки зрения влияния стороннего шума, исходящего от окружающей среды,

на кудит и представляется как использование в квантовых вентилях нормальной случайной величины с нулевым математическим ожиданием и единичной дисперсией. Вместе с тем в работе представлены подробные псевдокоды функционирования как самого модифицированного квантово-инспирированного генетического алгоритма численной оптимизации, так и его отдельных операций. Тестирование осуществляется путем проведения вычислительных экспериментов с выполнением модифицированного алгоритма на двумерных и многомерных функциях тестовых задач оптимизации, а также при решении прикладной оптимизационной задачи планирования гибридного поточного производства в обрабатывающей промышленности на основе финансовых затрат и решении задачи повышения точности прогнозирования на основе компактных машин экстремального обучения. Результаты экспериментов демонстрируют превосходство нового алгоритма над QIGA и классическими оптимизационными алгоритмами в точности решения, скорости сходимости с целевым значением глобального максимума и временем выполнения алгоритма.

Ключевые слова: квантово-инспирированный алгоритм, генетический алгоритм, численная оптимизация, кудит, сфера Блоха, матрица плотности, квантовая суперпозиция состояний, квантовая декогеренция

Благодарности. Данная работа выполнена при поддержке Министерства науки и высшего образования Российской Федерации, тема № FSFZ-2024-0023 «Методы выявления и обработки инцидентов в программном обеспечении на основе интеллектуального анализа мультимодальных векторных представлений текстов программ с применением технологий машинного и глубокого обучения».

ОБРАЗЕЦ ЦИТИРОВАНИЯ: Масленников В.В., Демидова Л.А. Модификация квантово-инспирированного генетического алгоритма численной оптимизации с использованием кудита в условиях имитации квантовой декогеренции // Computational Nanotechnology. 2024. Т. 11. № 2. С. 58–85. DOI: 10.33693/2313-223X-2024-11-2-58-85. EDN: MRWGYA

DOI: 10.33693/2313-223X-2024-11-2-58-85

Modification of a Quantum-inspired Genetic Algorithm for Numerical Optimization Using Qudit under Conditions of Simulating Quantum Decoherence

V.V. Maslennikov[a] ©, L.A. Demidova[b] ©

MIREA – Russian Technological University,
Moscow, Russian Federation

[a] **E-mail:** vldmsn@yahoo.com

[b] **E-mail:** liliya.demidova@rambler.ru

Abstract. The genetic algorithm for numerical optimization (GA) of the metaheuristic class is a method for finding optimal solutions based on the biological principles of natural selection and variability. GA is characterized by high operating speed, resistance to noise in the data, low probability of hitting the local extremum of the multimodal objective function, as well as the simultaneous application of probabilistic and deterministic rules for generating search space points. An alternative to the classical GA is the quantum-inspired genetic algorithm for numerical optimization (QIGA), which has advantages that are unattainable for GA by using the concepts and principles of quantum computing. The article proposes a new approach to the implementation of a quantum-inspired genetic numerical optimization algorithm for searching for the global maximum of the objective function, based on modeling the functioning of the GA by simulating the execution of quantum calculations based on qudit in the conditions of the existence of quantum decoherence in the era of noisy medium-scale quantum algorithms. For this purpose, to carry out quantum operations of rotating the states of multilevel quantum systems, the paper presents a density matrix based on Heisenberg–Weyl operators as an analogue of the Bloch sphere for qudits. The simulation of quantum decoherence is interpreted from the point of view of the influence of extraneous noise emanating from the environment on the qudit and is presented as the use of a normal random variable with zero mathematical expectation and unit variance in quantum gates. At the same time, the work presents detailed pseudocodes of the functioning of both the most modified quantum-inspired genetic algorithm for numerical optimization and its individual operations. Testing is carried out by conducting computational experiments with the implementation of a modified algorithm on two-dimensional and multidimensional functions of test optimization problems, as well as when solving an applied optimization problem of planning hybrid flow production in the manufacturing industry based on financial costs and solving the problem of increasing forecasting accuracy based on compact extreme learning machines. The experimental results demonstrate the superiority of the new algorithm over QIGA and classical optimization algorithms in the accuracy of the solution, the speed of convergence with the target value of the global maximum and the execution time of the algorithm.

Key words: quantum-inspired algorithm, genetic algorithm, numerical optimization, qudit, Bloch sphere, density matrix, quantum superposition of states, quantum decoherence

Acknowledgments. The work was supported by the Ministry of Science and Higher Education of the Russian Federation (Project No. FSFZ-2024-0023).

FOR CITATION: Maslennikov V.V., Demidova L.A. Modification of a Quantum-inspired Genetic Algorithm for Numerical Optimization Using Qudit under Conditions of Simulating Quantum Decoherence. *Computational Nanotechnology*. 2024. Vol. 11. No. 2. Pp. 58–85. (In Rus.). DOI: 10.33693/2313-223X-2024-11-2-58-85. EDN: MRWGYA

1. ВВЕДЕНИЕ

В октябре 2019 г. исследователями из отдела квантового искусственного интеллекта компании Google опубликована статья [1], в которой говорится о достижении «квантового превосходства». Научным коллективом под руководством Джона Мартиниса заявлено о решении задачи, которая не поддается решению на обычном классическом компьютере, с применением физического квантового вычислительного устройства. Эта задача заключается в выполнении случайной, но точно известной последовательности однокубитных и двухкубитных операций, превращении получающегося состояния кубитов в числовую строку с повторением процедуры миллионы раз и построении неслучайного распределения вероятности нахождения кубитов в определенных состояниях. Оценочное время решения задачи с 53-кубитным процессором Sycamore составило 200 секунд, в то время как самый мощный классический компьютер Summit должен проводить вычисления при решении этой задачи около 10 тысяч лет.

Указанная задача не является прикладной и единственное возможное ее практическое применение заключается в генерации случайных чисел. Также необходимо отметить, что в связи с расплывчатой формулировкой термина «квантового превосходства» авторы выбрали относительно простую задачу для его доказательства, которая при этом недоступна для решения на классическом компьютере за разумный период времени.

Действительно, несмотря на то, что научным сообществом проводились исследования по классическому моделированию квантовых схем с целью оптимизации алгоритмов для классических компьютеров [8; 9; 14], это не смогло принести пользу в нахождении полиноминального классического решения для класса недетерминировано полиноминальных задач, что свидетельствует о невозможности получения результатов квантовых вычислений при выполнении трудноразрешимых задач на классических вычислительных устройствах на текущий момент времени в условиях ограниченности технического и технологического развития человечества.

Однако согласно работам [2; 15; 19; 33] при решении стандартных задач, изначально предназначенных для выполнения на классических компьютерах, существует альтернативный подход на основе имитации квантовых вычислений, способный значительно ускорить нахождение лучшего решения той или иной задачи. Такой подход называется «квантово-инспирированным». Например, в соответствии с [2] при изучении практической эффективности квантово-инспирированных алгоритмов для рекомендательных систем и линейных систем уравнений было доказано, что данные алгоритмы обладают свойством полилогарифмического масштабирования до заданной размерности, что позволяет получить асимптотическое экспоненциальное ускорение по сравнению с ранее известными классическими методами решения задач, связанных с матрицами низкого ранга, но с ограничениями в сложности, подразумевающими значительную верхнюю границу полиноминальной сложности, в сравнении с квантовыми вычислениями.

При рассмотрении квантово-инспирированных оптимизационных алгоритмов [3; 25; 33] также имеется ряд положительных аспектов. В силу того, что квантово-инспирированные оптимизационные алгоритмы выполняются на базе концепций и принципов квантовых вычислений посредством моделирования кубитов, они обладают преимуществами, которые недостижимы для обычных оптимизационных алгоритмов. Так, например, доказано, что квантово-инспирированный генетический алгоритм значительно превосходит стандартный генетический алгоритм по времени выполнения, скорости сходимости и точности решения [25].

Главной целью текущего исследования является рассмотрение нового подхода к реализации квантово-инспирированного генетического алгоритма численной оптимизации [16], заключающегося в моделировании функционирования классического генетического алгоритма имитацией квантовых вычислений с использованием кудита в условиях существования квантовой декогеренции эпохи зашумленных квантовых алгоритмов среднего масштаба (Noisy intermediate-scale quantum era, далее – NISQ-эра).

В рамках решения поставленной цели и для понимания последующих рассуждений необходимо дать определения наиболее важным терминам из теории квантовых вычислений.

Сначала следует дать определение термину «кубит» и выразить его в математической интерпретации.

Определение 1. Кубит является основной единицей квантовой информации, представляющий собой нормализованный кет-вектор в простєранстве $\mathbb{R}^2$, охватываемом базисными векторами $|0\rangle$ и $|1\rangle$, и задающийся уравнением:

$$|\psi\rangle = \alpha|0\rangle + \beta|1\rangle, \tag{1}$$

где

$$|0\rangle = \begin{pmatrix} 1 \\ 0 \end{pmatrix}; \quad |1\rangle = \begin{pmatrix} 0 \\ 1 \end{pmatrix};$$

α, β – амплитуды вероятностей при $\alpha, \beta \in \mathbb{C}$ и $|\alpha|^2 + |\beta|^2 = 1$.

Представить кубит также возможно в виде сферы Блоха (рис. 1). Тогда амплитуды вероятностей рассчитываются как $\alpha = \cos(\theta/2)$ и $\beta = e^{i\varphi}\sin(\theta/2)$, где θ и φ – угловые координаты на сфере Блоха.

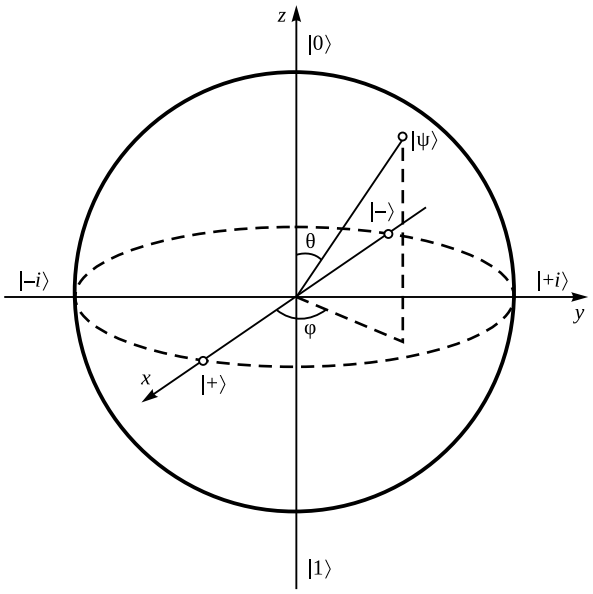

Рис. 1. Представление элементарного кубита в виде сферы Блоха

Fig. 1. Representation of an elementary qubit in the form of a Bloch sphere

Таким образом, исходное состояние квантовой системы, состоящей из одного кубита, возможно описать эквивалентным образом на основе уравнения (1) при помощи двух вещественных параметров θ и φ:

$$|\psi\rangle = \cos\left(\frac{\theta}{2}\right)|0\rangle + e^{i\varphi}\sin\left(\frac{\theta}{2}\right)|1\rangle. \quad (2)$$

Далее следует дать определение термину «кудит» [32].

Определение 2. Кудит является квантовой системой, находящейся в d-мерном состоянии, которое возможно описать вектором в d-мерном Гильбертовом пространстве $\mathfrak{H}_d$. В этом случае пространство квантовой системы заполняется множеством ортонормированных базисных векторов $\{|0\rangle, |1\rangle, |2\rangle, |3\rangle, \ldots, |d-1\rangle\}$, а общий вид состояния кудита выражается в следующем виде:

$$|\psi\rangle = \alpha_0|0\rangle + \alpha_1|1\rangle + \alpha_2|2\rangle + \alpha_3|3\rangle + \ldots + \alpha_{d-1}|d-1\rangle = (\alpha_0, \alpha_1, \alpha_2, \alpha_3, \ldots, \alpha_{d-1}) \in \mathbb{C}_d, \quad (3)$$

где $|\psi\rangle$ представляет собой квантовую систему, находящуюся одновременно в более, чем двух состояниях;

$\alpha_0, \ldots, \alpha_{d-1}$ – амплитуды вероятностей при $\alpha_0, \ldots, \alpha_{d-1} \in \mathbb{C}^d$;

$|\alpha_0|^2 + |\alpha_1|^2 + |\alpha_2|^2 + |\alpha_3|^2 + \ldots + |\alpha_{d-1}|^2 = 1$.

Также следует рассмотреть значение термина «квантовая декогеренция» [26; 27].

Определение 3. Квантовая декогеренция представляет собой эффект потери квантовой когерентности, в процессе которого поведение системы S изменяется с поведения, характеризующегося условиями квантовой механики, на то, которое возможно объяснить классической механикой. В этом случае полезность эффекта квантовой декогеренции интерпретируется с точки зрения ее применения к анализу вероятностей до и после взаимодействия с окружающей средой.

Используя нотацию и постулаты квантовой механики [22], исходное состояние системы S можно определить как

$$|\psi\rangle = \sum_i |i\rangle\langle i|\psi\rangle, \quad (4)$$

где $|i\rangle$ в совокупности образуют индуцированный окружающей средой выбранный собственный базис.

Пусть начальное состояние окружающей среды определено как $|\varepsilon\rangle$. Тогда перед взаимодействием между двумя подсистемами общее состояние их связи возможно выразить как

$$|\psi_{\text{prev}}\rangle = \sum_i |i\rangle \otimes |\varepsilon\rangle\langle i|\psi\rangle, \quad (5)$$

где $\otimes$ – тензорное произведение $|i\rangle$ и $|\varepsilon\rangle$ с учетом того, что векторный базис комбинации системы S и окружающей среды представляет собой множество тензорных произведений базисных векторов двух подсистем.

В случае, когда окружающая среда «поглощает» систему S, каждый элемент системы S связывается с окружающей средой и тензорное произведение $|i\rangle \otimes |\varepsilon\rangle$ преобразуется в $|\varepsilon_i\rangle$, вследствие чего состояние $|\psi_{\text{prev}}\rangle$ переходит в состояние

$$|\psi_{\text{after}}\rangle = \sum_i |\varepsilon_i\rangle\langle i|\psi\rangle. \quad (6)$$

При наблюдении за системой, совершающей переход $\psi \to \varphi$ до взаимодействия системы S с окружающей средой, в соответствии с правилом Борна вероятность перехода равняется квадрату модуля скалярного произведения двух состояний и вычисляется следующим образом:

$$P_{\text{prev}}(\psi \to \varphi) = \left|\langle\psi|\varphi\rangle\right|^2 = \left|\sum_i \langle\psi|i\rangle\langle i|\varphi\rangle\right|^2 = \sum_i \left|\langle\psi|i\rangle\langle i|\varphi\rangle\right|^2 + \sum_{ij} \langle\psi|i\rangle\langle j|\psi\rangle\langle\varphi|j\rangle\langle i|\varphi\rangle, \quad (7)$$

где увеличение вероятности перехода предполагает выполнение условия $i \neq j$, которое возможно рассматривать с точки зрения представления интерференции между различными базовыми элементами или квантовыми альтернативами.

При наблюдении за системой, совершающей переход $\psi \to \varphi$ после взаимодействия системы S с окружающей средой, по правилу Борна перед возведением

модуля в квадрат требуется найти сумму всех возможных состояний $|\varepsilon_i\rangle$ окружающей среды:

$$\begin{aligned} P_{\text{after}}(\psi \to \varphi) &= \sum_j \left|\left\langle \psi_{\text{after}} | \varphi,\ \varepsilon_j \right\rangle\right|^2 = \\ &= \sum_j \left|\sum_i \langle \psi | i \rangle \langle i,\ \varepsilon_i | \varphi,\ \varepsilon_j \rangle\right|^2 = \\ &= \sum_j \left|\sum_i \langle \psi | i \rangle \langle i | \varphi \rangle \langle \varepsilon_i | \varepsilon_j \rangle\right|^2 \approx \sum_j \left|\langle \psi | j \rangle \langle j | \varphi \rangle\right|^2 = \\ &= \sum_i \left|\langle \psi | i \rangle \langle i | \varphi \rangle\right|^2, \end{aligned} \tag{8}$$

с учетом применения приближенного равенства $\langle \varepsilon_i | \varepsilon_j \rangle \approx \delta_{ij}$, предполагающего, что декогеренция становится суперселекцией, вызванной окружающей средой [34].

Если говорить про квантовую декогеренцию с точки зрения квантовых вычислений, проводящихся на базе физических квантовых вычислительных устройств, то текущее их состояние находится в условиях NISQ-эры [24]. Данная эра характеризуется квантовыми процессорами до 1000 кубитов, развитие которых на текущий момент времени не является достаточным для достижения удовлетворительного уровня отказоустойчивости. Такие процессоры подвержены влиянию стороннего шума, исходящего от окружающей среды, из-за чего проявляется эффект квантовой декогеренции.

2. МЕТОДЫ И МАТЕРИАЛЫ

2.1. Сфера Блоха для кудитов

Кубит как двухуровневая квантовая система может быть представлен в виде трехмерного вектора таким образом, что каждая точка, располагающаяся внутри сферы Блоха (см. рис. 1), соответствует физическому состоянию кубита с определенной амплитудой вероятности. Состояние кубита получается за счет вращений сферы Блоха, соответствующих унитарным операциям с соблюдением условия

$$U^\dagger U = UU^\dagger = E \text{ при } U^{-1} = U^\dagger,$$

где U – ограниченный линейный оператор;

$U^\dagger$ – эрмитово-сопряженный к U оператор;

E – единичная матрица.

Однако описывать состояния высокой размерности $d \geq 3$ при помощи сферы Блоха в явном виде не представляется возможным. По этой причине для кудитов предлагается использовать аналог сферы Блоха, основанный на использовании операторов Гейзенберга–Вейля [28].

Базис операторов Гейзенберга–Вейля определяется как

$$\left\{U_{00} = E,\ U_{pq} = \omega^{-\frac{pq}{2}} Q_d |p\rangle P_d |q\rangle,\ \left(p,\ q = \overline{0,\ d-1}\right)\right\},$$

где унитарный оператор U_{pq} строится на основе общих операторов Q_d, P_d, соответствующих операторам поворота Паули Z и X.

Используя базис Гейзенберга–Вейля, разложение ограниченного оператора матрицы плотности в $\mathbb{C}^d$ [4] можно представить в следующем виде:

$$\begin{aligned} \rho &= \frac{1}{d}\sum_{p=q=0}^{d-1} b_{pq} U_{pq} = \frac{1}{d}\left(E + \sum_{p\neq 0,\ q\neq 0} b_{pq} U_{pq}\right) = \\ &= \frac{1}{d}\left(E + \sum_{p\neq 0,\ q\neq 0} b_{pq} \omega^{-\frac{pq}{2}} Q_d |p\rangle P_d |q\rangle\right) = \\ &= \frac{1}{d}\left(E + \sum_{p\neq 0,\ q\neq 0} b_{pq} e^{-\frac{i\pi pq}{d}} Q_d |p\rangle P_d |q\rangle\right) = \\ &= \frac{1}{d}\left(E + \sum_{p\neq 0,\ q\neq 0} b_{pq} (-1)^{-\frac{pq}{d}} Q_d |p\rangle P_d |q\rangle\right), \end{aligned} \tag{9}$$

где ρ – матрица плотности, описывающая состояние квантовой системы, состоящей из кудита размерности d;

$\omega := e^{2i\pi/d}$, $e^{i\pi} = -1$ согласно тождеству Эйлера;

$b_{00} = 1$ и $b_{pq} = \operatorname{tr}(\rho U_{pq}^\dagger)$ формируют компоненты вектора Блоха.

При этом сферообразная геометрическая конструкция Блоха принадлежит пространству $\mathbb{R}^{(d^2-1)/2}$ при $d \in \mathbb{P}$ и пространству $\mathbb{R}^{(d^2+2)/2}$ в случае $d \notin \mathbb{P}$.

Операторы Паули P_d и Q_d определяются как:

$$P_d|q\rangle = |(q+1) \bmod d\rangle; \tag{10}$$

$$Q_d|p\rangle = \omega_d^p|p\rangle = (-1)^{2p/d}|p\rangle, \tag{11}$$

где mod d обозначает конгруэнтность по модулю d на множестве $\mathbb{Z}$.

В качестве примера, используя разложение (9), представим куквинт ($d = 5$) на сфере Блоха пространства $\mathbb{R}^{12}$:

$$\begin{aligned} \rho = 1/5(&E + b_{01}U_{01} + b_{02}U_{02} + b_{03}U_{03} + b_{04}U_{04} + \\ &+ b_{10}U_{10} + b_{11}U_{11} + b_{12}U_{12} + b_{13}U_{13} + \\ &+ b_{14}U_{14} + b_{20}U_{20} + b_{21}U_{21} + b_{22}U_{22} + \\ &+ b_{23}U_{23} + b_{24}U_{24} + b_{30}U_{30} + b_{31}U_{31} + b_{32}U_{32} + \\ &+ b_{33}U_{33} + b_{34}U_{34} + b_{40}U_{40} + b_{41}U_{41} + \\ &+ b_{42}U_{42} + b_{43}U_{43} + b_{44}U_{44}). \end{aligned} \tag{12}$$

Согласно свойству $\rho^\dagger = \rho$ коэффициенты b_{pq} подчиняются следующим соотношениям:

$$\begin{gathered} b_{10} = n_1 e^{i\theta_1};\quad b_{40} = n_1 e^{-i\theta_1};\quad b_{20} = n_2 e^{i\theta_2};\quad b_{30} = n_2 e^{-i\theta_2}; \\ b_{01} = n_3 e^{i\theta_3};\quad b_{04} = n_3 e^{-i\theta_3};\quad b_{02} = n_4 e^{i\theta_4};\quad b_{03} = n_4 e^{-i\theta_4}; \\ b_{11} = n_5 e^{i\theta_5};\quad b_{44} = n_5 e^{-i\theta_5};\quad b_{23} = n_6 e^{i\theta_6};\quad b_{32} = n_6 e^{-i\theta_6}; \\ b_{12} = n_7 e^{i\theta_7};\quad b_{43} = n_7 e^{-i\theta_7};\quad b_{21} = n_8 e^{i\theta_8};\quad b_{34} = n_8 e^{-i\theta_8}; \\ b_{13} = n_9 e^{i\theta_9};\quad b_{42} = n_9 e^{-i\theta_9};\quad b_{24} = n_{10} e^{i\theta_{10}};\quad b_{31} = n_{10} e^{-i\theta_{10}}; \\ b_{14} = n_{11} e^{i\theta_{11}};\quad b_{41} = n_{11} e^{-i\theta_{11}};\quad b_{22} = n_{12} e^{i\theta_{12}}; \\ b_{33} = n_{12} e^{-i\theta_{12}}, \end{gathered} \tag{13}$$

где n_i, $\theta_i \in \mathbb{R}$.

Конечное представление куквинта в виде матрицы плотности реализуется путем вынесения в (12) общих множителей, использования унитарного оператора $U_{pq} = (-1)^{-pq/d} Q_d|p\rangle P_d|q\rangle$ с раскрытием $Q_d|p\rangle$ и $P_d|q\rangle$ через (10) и (11), а также подстановки (13) в (12):

$$
\begin{gathered}
\rho = \frac{1}{5}\Big(E + n_1 e^{i\theta_1} U_{10} + n_1 e^{-i\theta_1} U_{40} + n_2 e^{i\theta_2} U_{20} + n_2 e^{-i\theta_2} U_{30} + n_3 e^{i\theta_3} U_{01} + n_3 e^{-i\theta_3} U_{04} + n_4 e^{i\theta_4} U_{02} + n_4 e^{-i\theta_4} U_{03} + \\
+ n_5 e^{i\theta_5} U_{11} + n_5 e^{-i\theta_5} U_{44} + n_6 e^{i\theta_6} U_{23} + n_6 e^{-i\theta_6} U_{32} + n_7 e^{i\theta_7} U_{12} + n_7 e^{-i\theta_7} U_{43} + n_8 e^{i\theta_8} U_{21} + n_8 e^{-i\theta_8} U_{34} + n_9 e^{i\theta_9} U_{13} + n_9 e^{-i\theta_9} U_{42} + \\
+ n_{10} e^{i\theta_{10}} U_{24} + n_{10} e^{-i\theta_{10}} U_{31} + n_{11} e^{i\theta_{11}} U_{14} + n_{11} e^{-i\theta_{11}} U_{41} + n_{12} e^{i\theta_{12}} U_{22} + n_{12} e^{-i\theta_{12}} U_{33}\Big) = \\
= \frac{1}{5}\Big(E + n_1\left(e^{i\theta_1} U_{10} + e^{-i\theta_1} U_{40}\right) + n_2\left(e^{i\theta_2} U_{20} + e^{-i\theta_2} U_{30}\right) + n_3\left(e^{i\theta_3} U_{01} + e^{-i\theta_3} U_{04}\right) + n_4\left(e^{i\theta_4} U_{02} + e^{-i\theta_4} U_{03}\right) + \\
+ n_5\left(e^{i\theta_5} U_{11} + e^{-i\theta_5} U_{44}\right) + n_6\left(e^{i\theta_6} U_{23} + e^{-i\theta_6} U_{32}\right) + n_7\left(e^{i\theta_7} U_{12} + e^{-i\theta_7} U_{43}\right) + n_8\left(e^{i\theta_8} U_{21} + e^{-i\theta_8} U_{34}\right) + \\
+ n_9\left(e^{i\theta_9} U_{13} + e^{-i\theta_9} U_{42}\right) + n_{10}\left(e^{i\theta_{10}} U_{24} + e^{-i\theta_{10}} U_{31}\right) + n_{11}\left(e^{i\theta_{11}} U_{14} + e^{-i\theta_{11}} U_{41}\right) + n_{12}\left(e^{i\theta_{12}} U_{22} + e^{-i\theta_{12}} U_{33}\right)\Big) = \\
= \frac{1}{5}\Bigg(E + \frac{\mathrm{tr}(\rho H_1)}{2}\left(e^{i\theta_1}(-1)^{-\frac{1*0}{5}} Q_5|1\rangle P_5|0\rangle + e^{-i\theta_1}(-1)^{-\frac{4*0}{5}} Q_5|4\rangle P_5|0\rangle\right) + \\
+ \frac{\mathrm{tr}(\rho H_2)}{2}\left(e^{i\theta_2}(-1)^{-\frac{2*0}{5}} Q_5|2\rangle P_5|0\rangle + e^{-i\theta_2}(-1)^{-\frac{3*0}{5}} Q_5|3\rangle P_5|0\rangle\right) + \\
+ \frac{\mathrm{tr}(\rho H_3)}{2}\left(e^{i\theta_3}(-1)^{-\frac{0*1}{5}} Q_5|0\rangle P_5|1\rangle + e^{-i\theta_3}(-1)^{-\frac{0*4}{5}} Q_5|0\rangle P_5|4\rangle\right) + \\
+ \frac{\mathrm{tr}(\rho H_4)}{2}\left(e^{i\theta_4}(-1)^{-\frac{0*2}{5}} Q_5|0\rangle P_5|2\rangle + e^{-i\theta_4}(-1)^{-\frac{0*3}{5}} Q_5|0\rangle P_5|3\rangle\right) + \\
+ \frac{\mathrm{tr}(\rho H_5)}{2}\left(e^{i\theta_5}(-1)^{-\frac{1*1}{5}} Q_5|1\rangle P_5|1\rangle + e^{-i\theta_5}(-1)^{-\frac{4*4}{5}} Q_5|4\rangle P_5|4\rangle\right) + \\
+ \frac{\mathrm{tr}(\rho H_6)}{2}\left(e^{i\theta_6}(-1)^{-\frac{2*3}{5}} Q_5|2\rangle P_5|3\rangle + e^{-i\theta_6}(-1)^{-\frac{3*2}{5}} Q_5|3\rangle P_5|2\rangle\right) + \\
+ \frac{\mathrm{tr}(\rho H_7)}{2}\left(e^{i\theta_7}(-1)^{-\frac{1*2}{5}} Q_5|1\rangle P_5|2\rangle + e^{-i\theta_7}(-1)^{-\frac{4*3}{5}} Q_5|4\rangle P_5|3\rangle\right) + \\
+ \frac{\mathrm{tr}(\rho H_8)}{2}\left(e^{i\theta_8}(-1)^{-\frac{2*1}{5}} Q_5|2\rangle P_5|1\rangle + e^{-i\theta_8}(-1)^{-\frac{3*4}{5}} Q_5|3\rangle P_5|4\rangle\right) + \\
+ \frac{\mathrm{tr}(\rho H_9)}{2}\left(e^{i\theta_9}(-1)^{-\frac{1*3}{5}} Q_5|1\rangle P_5|3\rangle + e^{-i\theta_9}(-1)^{-\frac{4*2}{5}} Q_5|4\rangle P_5|2\rangle\right) + \\
+ \frac{\mathrm{tr}(\rho H_{10})}{2}\left(e^{i\theta_{10}}(-1)^{-\frac{2*4}{5}} Q_5|2\rangle P_5|4\rangle + e^{-i\theta_{10}}(-1)^{-\frac{3*1}{5}} Q_5|3\rangle P_5|1\rangle\right) + \\
+ \frac{\mathrm{tr}(\rho H_{11})}{2}\left(e^{i\theta_{11}}(-1)^{-\frac{1*4}{5}} Q_5|1\rangle P_5|4\rangle + e^{-i\theta_{11}}(-1)^{-\frac{4*1}{5}} Q_5|4\rangle P_5|1\rangle\right) + \\
+ \frac{\mathrm{tr}(\rho H_{12})}{2}\left(e^{i\theta_{12}}(-1)^{-\frac{2*2}{5}} Q_5|2\rangle P_5|2\rangle + e^{-i\theta_{12}}(-1)^{-\frac{3*3}{5}} Q_5|3\rangle P_5|3\rangle\right)\Bigg) = \\
= \frac{1}{5}\Bigg(E + \frac{\mathrm{tr}(\rho H_1)}{2}\left(e^{i\theta_1}(-1)^{\frac{2}{5}}|1\rangle|1\rangle + e^{-i\theta_1}(-1)^{\frac{8}{5}}|4\rangle|1\rangle\right) + \frac{\mathrm{tr}(\rho H_2)}{2}\left(e^{i\theta_2}(-1)^{\frac{4}{5}}|2\rangle|1\rangle + e^{-i\theta_2}(-1)^{\frac{6}{5}}|3\rangle|1\rangle\right) + \\
+ \frac{\mathrm{tr}(\rho H_3)}{2}\left(e^{i\theta_3}|0\rangle|2\rangle + e^{-i\theta_3}|0\rangle|0\rangle\right) + \frac{\mathrm{tr}(\rho H_4)}{2}\left(e^{i\theta_4}|0\rangle|3\rangle + e^{-i\theta_4}|0\rangle|4\rangle\right) + \frac{\mathrm{tr}(\rho H_5)}{2}\left(e^{i\theta_5}(-1)^{\frac{1}{5}}|1\rangle|2\rangle + e^{-i\theta_5}(-1)^{-\frac{8}{5}}|4\rangle|0\rangle\right) + \\
+ \frac{\mathrm{tr}(\rho H_6)}{2}\left(e^{i\theta_6}(-1)^{-\frac{2}{5}}|2\rangle|4\rangle + e^{-i\theta_6}|3\rangle|3\rangle\right) + \frac{\mathrm{tr}(\rho H_7)}{2}\left(e^{i\theta_7}|1\rangle|3\rangle + e^{-i\theta_7}(-1)^{-\frac{4}{5}}|4\rangle|4\rangle\right) + \\
+ \frac{\mathrm{tr}(\rho H_8)}{2}\left(e^{i\theta_8}(-1)^{\frac{2}{5}}|2\rangle|2\rangle + e^{-i\theta_8}(-1)^{-\frac{6}{5}}|3\rangle|0\rangle\right) + \frac{\mathrm{tr}(\rho H_9)}{2}\left(e^{i\theta_9}(-1)^{-\frac{1}{5}}|1\rangle|4\rangle + e^{-i\theta_9}|4\rangle|3\rangle\right) + \\
+ \frac{\mathrm{tr}(\rho H_{10})}{2}\left(e^{i\theta_{10}}(-1)^{-\frac{4}{5}}|2\rangle|0\rangle + e^{-i\theta_{10}}(-1)^{\frac{3}{5}}|3\rangle|2\rangle\right) + \frac{\mathrm{tr}(\rho H_{11})}{2}\left(e^{i\theta_{11}}(-1)^{-\frac{2}{5}}|1\rangle|0\rangle + e^{-i\theta_{11}}(-1)^{\frac{4}{5}}|4\rangle|2\rangle\right) + \\
+ \frac{\mathrm{tr}(\rho H_{12})}{2}\left(e^{i\theta_{12}}|2\rangle|3\rangle + e^{-i\theta_{12}}(-1)^{-\frac{3}{5}}|3\rangle|4\rangle\right)\Bigg) = \frac{1}{5}\left(E + \frac{1}{2}\sum_{i=1}^{12}\mathrm{tr}(\rho H_i) H_i\right),
\end{gathered}
\tag{14}
$$

где

$$n_i = \frac{\mathrm{tr}\left(\rho H_i\right)}{2};$$

H_i – эрмитова матрица;

$$H_i = e^{\mathrm{i}\theta_i}\,(-1)^{-\frac{pq}{5}}\,Q_5\,|p\rangle P_5\,|q\rangle + e^{-\mathrm{i}\theta_i}\,(-1)^{-\frac{pq}{5}}\,Q_5\,|p\rangle P_5\,|q\rangle;$$

θ_i – угол поворота, формирующийся в результате воздействия шума окружающей среды на куквинт.

Имитация влияния шума на кудит как виртуальную квантовую систему любой размерности рассматривается исходя из свойств и характеристик физической квантовой системы, подвергающейся воздействию внешних флуктуаций. Пусть в качестве квантовой системы используется оптический кудит на основе стабильного изотопа иттербия $^{171}\mathrm{Yb}^{+}$, управляемый высокостабильным лазером с узким спектральным распределением в видимом диапазоне [5]. Для обеспечения когерентности кудита требуется значительное понижение температуры иона. Это возможно достичь за счет применения магнитокалорического эффекта, благодаря которому иттербий, обладающий свойством парамагнетизма, изменяет свою температуру в адиабатических условиях при намагничивании или размагничивании. Однако образующееся при данном процессе магнитное поле порождает систематические сдвиги атомных уровней, возникающие в связи с квадратичным эффектом Зеемана от неконтролируемого остаточного магнитного поля [20].

Одновременно с шумом от магнитного поля на ион иттербия могут влиять шумы от модуляции тока накачки управляющего лазера, которые обуславливаются частотной модуляцией, изменением температуры и тока накачки, отражением излучения оптического сигнала от стыка с поверхностью оптического волокна, спонтанным излучением или перескоком моды.

Моделирование воздействия данных шумов на виртуальную квантовую систему возможно условно интерпретировать как дополнительное использование в квантовых вентилях нормальной случайной величины с нулевым математическим ожиданием и единичной дисперсией $N(0, 1)$ [36]. Это объясняется тем, что физическая величина, подвергающаяся влиянию большого числа случайных помех, строго подчиняется нормальному распределению. Таким образом, для (9) и в (14) угол поворота определяется как $\theta = \tau\xi$, где τ – уровень ошибки, $\xi \sim N\ (0, 1)$.

2.2. Модификация квантово-инспирированного генетического алгоритма численной оптимизации

Базовой «платформой» для модификации является алгоритм численной оптимизации, описанный в статье [16]. Его структура строится на основе концепций существования кубита (1), (2) и правила суперпозиции состояний квантовой механики – максимальной неопределенности квантовой системы, чьи состояния имеют равные вероятности существования. Неопределенность получается применением к системе вентиля Адамара:

$$|0\rangle \to \frac{|0\rangle + |1\rangle}{\sqrt{2}} = \frac{\begin{pmatrix}1\\0\end{pmatrix} + \begin{pmatrix}0\\1\end{pmatrix}}{\sqrt{2}} = \begin{pmatrix}\frac{1}{\sqrt{2}}\\ \frac{1}{\sqrt{2}}\end{pmatrix};$$

$$|1\rangle \to \frac{|0\rangle - |1\rangle}{\sqrt{2}} = \frac{\begin{pmatrix}1\\0\end{pmatrix} - \begin{pmatrix}0\\1\end{pmatrix}}{\sqrt{2}} = \begin{pmatrix}\frac{1}{\sqrt{2}}\\ -\frac{1}{\sqrt{2}}\end{pmatrix}; \tag{15}$$

$$H = \frac{1}{\sqrt{2}}\begin{pmatrix}1 & 1\\ 1 & -1\end{pmatrix},$$

где H – вентиль Адамара.

Тогда обобщенный вентиль Адамара для кудита H_d [32] имеет вид:

$$H_d\,|j\rangle = \frac{1}{\sqrt{d}}\sum_{i=0}^{d-1}(-1)^{\frac{2ij}{d}}\,|i\rangle, \tag{16}$$

где $j = \overline{0,\ d-1}$.

Так, неопределенность куквинта для каждого возможного состояния будет равняться следующим амплитудам вероятностей в комплексной форме:

$$H_5|0\rangle = \begin{pmatrix}0,4472135954999579 + 0j\\ 0,4472135954999579 + 0j\\ 0,4472135954999579 + 0j\\ 0,4472135954999579 + 0j\\ 0,4472135954999579 + 0j\end{pmatrix}; \tag{17}$$

$$H_5|1\rangle = \begin{pmatrix}0,4472135954999579 + 0j\\ 0,13819660112501053 + 0,42532540417601994j\\ -0,3618033988749894 + 0,2628655560595668j\\ -0,36180339887498947 - 0,26286555605956674j\\ 0,13819660112501048 - 0,42532540417601994j\end{pmatrix};$$

$$H_5|2\rangle = \begin{pmatrix}0,4472135954999579 + 0j\\ -0,3618033988749894 + 0,2628655560595668j\\ 0,13819660112501048 - 0,42532540417601994j\\ 0,13819660112501056 + 0,4253254041760199j\\ -0,3618033988749894 - 0,2628655560595667j\end{pmatrix};$$

$$H_5|3\rangle = \begin{pmatrix}0,4472135954999579 + 0j\\ -0,36180339887498947 - 0,26286555605956674j\\ 0,13819660112501056 + 0,4253254041760199j\\ 0,13819660112501042 - 0,4253254041760199j\\ -0,36180339887498936 + 0,2628655560595668j\end{pmatrix};$$

$$H_5|4\rangle = \begin{pmatrix}0,4472135954999579 + 0j\\ 0,13819660112501048 - 0,42532540417601994j\\ -0,3618033988749894 - 0,2628655560595667j\\ -0,36180339887498936 + 0,2628655560595668j\\ 0,13819660112501056 + 0,4253254041760197j\end{pmatrix}.$$

На начальном этапе работы алгоритма [16] гены всех хромосом в квантовой популяции $Q = \{q_1, q_2, q_3, \dots, q_i\}$ (где q_i – бинарная квантовая хромосома,

$$q_i = \begin{pmatrix} \alpha_1 & \alpha_2 & \alpha_3 & \dots & \alpha_m \\ \beta_1 & \beta_2 & \beta_3 & \dots & \beta_m \end{pmatrix},$$

в которой каждый столбец в матрице отображает бинарный квантовый ген $|\psi\rangle_1, \dots, |\psi\rangle_m$, $i = \overline{1, N}$; N – размер квантовой популяции, m – размер квантовой хромосомы) инициализируются при помощи линейной суперпозиции $\frac{1}{\sqrt{2}}|0\rangle + \frac{1}{\sqrt{2}}|1\rangle$, что эквивалентно равномерному распределению в пространстве поиска. При этом оценка функции приспособленности выполняется путем наблюдения за квантовой популяцией Q. Этот шаг характеризуется выбором квантовых хромосом в соответствии с распределениями вероятностей квантовой популяции $Q(t)$ (t – номер итерации). Все генетические операторы, применяемые в алгоритме, основываются на квантовых вентилях вращения, осуществляющих поворот векторов состояний в пространстве состояний квантового гена. Для поворота состояния квантового гена $|\psi\rangle$ на угол θ в двумерном пространстве используется квантовый вентиль $U(\theta)$. Исходя из этого обновление состояний квантовых генов происходит следующим образом:

$$|\psi\rangle_{t+1} = U(\theta)|\psi\rangle_t = \begin{pmatrix} \cos(\theta) & -\sin(\theta) \\ \sin(\theta) & \cos(\theta) \end{pmatrix} \begin{pmatrix} \alpha \\ \beta \end{pmatrix}. \quad (18)$$

Общий псевдокод квантово-инспирированного алгоритма численной оптимизации приведен в алгоритме 1.

Алгоритм 1

Квантово-инспирированный генетический алгоритм численной оптимизации

Вход: f: $\mathbb{R}^m \to \mathbb{R}$ ▷ функция приспособленности.
$n \in \mathbb{N}$ ▷ количество хромосом в популяции.
$\theta \in \mathbb{R}$ ▷ множество углов поворота состояний квантовых генов.

1. **Установить** номер поколения $t = 0$.
2. **Инициализировать** гены n хромосом квантовой популяции $Q(0)$.
3. **Создать** начальную популяцию $P(0)$ путем наблюдения за состояниями квантовой популяции $Q(0)$.
4. **Оценить** $P(0)$ на функции f.
5. **Сохранить** лучшее решение среди $P(0)$.
6. **Пока не выполнено** условие завершения **выполнять:**
7. $t \leftarrow t + 1$.
8. **Создать** $P(t)$ путем наблюдения за состояниями квантовой популяции $Q(t - 1)$.
9. **Оценить** $P(t)$ на функции f.
10. **Обновить** $Q(t)$ с использованием квантовых вентилей $U(\theta_t)$.
11. **Сохранить** лучшее решение среди $P(t)$.
12. **Завершить цикл.**
13. **Возвратить** лучшее решение, найденное в процессе эволюции.

Модифицированный квантово-инспирированный генетический алгоритм численной оптимизации с использованием кудита в условиях имитации квантовой декогеренции направлен на поиск глобального максимума оптимизируемой функции. На вход алгоритма подается набор целочисленных значений, включающий в себя размер квантовой популяции, длину квантовой хромосомы, порядковый номер текущего поколения, максимальное количество поколений, длину кудита, используемого для вычислений, уровень ошибки τ, вызванной влиянием шума на кудит, значение показателя частоты мутации в популяции, значение показателя вероятности мутации, а также набор кортежей, которые предназначены как для первоначального хранения состояний входного кудита заданной длины, углов поворота θ состояний квантовых генов, углов поворота θ со смещением Δ состояний квантовых генов, так и последующего хранения вероятностей существования состояний генов квантовых хромосом и бинарных значений генов классических хромосом, порядковых номеров лучших квантовых хромосом каждого поколения.

Далее осуществляется инициализация генов квантовой популяции (алгоритм 3). На первом этапе в зависимости от того, является ли число, характеризующее длину кудита *qudit_len*, простым или составным, определяется пространство $\mathbb{R}^{(qudit_len^2 - 1)/2}$ или $\mathbb{R}^{(qudit_len^2 + 2)/2}$, в соответствии с которым будут выполняться все последующие квантовые операции. Затем вычисляются углы поворота θ состояний квантовых генов в соответствующем пространстве $\mathbb{R}$. После этого для каждого квантового состояния $|\psi\rangle$ кудита вычисляются комплексные амплитуды вероятностей в условии неопределенности $H_{qudit_len}|\psi\rangle$ применением к кудиту вентиля Адамара (16) и матрица плотности ρ (9), чье произведение дает амплитуды вероятностей состояний квантовых генов после их вращения (алгоритм 2). Рассчитанные амплитуды вероятностей

преобразовываются в вероятности существования состояний генов квантовых хромосом, в зависимости от которых задаются бинарные значения генов классических хромосом. Заключительным действием в инициализации является конвертация кортежей значений генов классических хромосом из двоичной системы счисления в целочисленные значения в десятичной системе счисления.

Алгоритм 2

Вычисление квантовых и классических хромосом

Вход: $pop_size \in \mathbb{N}$ ▷ размер квантовой популяции.

$chrom_len \in \mathbb{N}$ ▷ длина квантовой хромосомы.

$qudit_len \in \mathbb{N}$ ▷ длина кудита.

$\theta \in \mathbb{R}$ ▷ кортеж углов поворота состояний квантовых генов $|\psi\rangle_1 \ldots |\psi\rangle_{chrom_len}$.

$qcv = \langle\langle\langle\langle Pr_n\rangle_\psi\rangle_j\rangle_i$: $j \in [0, 1, chrom_len - 1]$; $i \in [0, 1, pop_size - 1]$; $\psi, n \in [0, 1, qudit_len - 1]\rangle$ ▷ вектор квантовых хромосом, представляет собой кортеж кортежей с кортежами кортежей, содержащими нулевые значения вероятностей Pr.

$ccv = \langle\langle\langle\langle a_n\rangle_\psi\rangle_j\rangle_i$: $j \in [0, 1, chrom_len - 1]$; $i \in [0, 1, pop_size - 1]$; $\psi, n \in [0, 1, qudit_len - 1]\rangle$ ▷ вектор классических хромосом, представляет собой кортеж кортежей с кортежами кортежей, содержащими нулевые значения a результатов измерения состояний квантовых хромосом qcv.

$qudit_state = \langle|\psi\rangle$: $\psi \in [0, 1, qudit_len - 1]\rangle$ ▷ кортеж состояний кудита длины $qudit_len$.

1. $z = \langle(qudit_len^2 - 1)/2, (qudit_len^2 + 2)/2\rangle$ ▷ кортеж размерностей пространства выполнения квантовых операций.
2. $d_ccv = ccv$ ▷ копия вектора классических хромосом ccv.
3. $i \in [1, 2, pop_size]$ ▷ номер итерации относительно pop_size.
4. $j \in [1, 2, chrom_len]$ ▷ номер итерации относительно $chrom_len$.
5. $h_prob = \left(\frac{1}{\sqrt{qudit_len}}\right)^2$ ▷ значение вероятности существования состояния $|0\rangle$ кудита в условии неопределенности.
6. **Для каждого** состояния кудита $|\psi\rangle \in qudit_state$ **выполнять:**
7. $H_{qudit_len}|\psi\rangle = \frac{1}{\sqrt{qudit_len}} \sum_{l=0}^{qudit_len-1} (-1)^{\frac{2l\psi}{qudit_len}} |l\rangle$ ▷ применить вентиль Адамара к кудиту в состоянии $|\psi\rangle$ и вычислить амплитуды вероятностей в условии неопределенности.
8. $H = \varnothing$ ▷ кортеж эрмитовых матриц.
9. $H \leftarrow H \cup \left((-1)^{\frac{p(2-q)}{qudit_len}} \left(e^{i\theta_m}|p\rangle|(q+1)\bmod qudit_len\rangle + e^{-i\theta_m}|p\rangle|(q+1)\bmod qudit_len\rangle\right)\right)$ ▷ вычислить эрмитовы матрицы и последовательно добавить их в конец кортежа H при $\theta_m \in \theta$; $p, q = \overline{0, qudit_len - 1}$ с учетом свойства $\rho^\dagger = \rho$.
10. $\rho = \frac{1}{qudit_len}\left(E + \frac{1}{2}\sum_{m=1}^{z} \mathrm{tr}(\rho H_m) H_m\right)$ ▷ представить кудит в виде матрицы плотности ρ при $H_m \in H$.
11. $prob_amp = \langle H_{qudit_len}|\psi\rangle^*\rho\rangle$ ▷ рассчитать амплитуды вероятностей и сохранить результат в виде кортежа.
12. **Преобразовать** амплитуды вероятностей $\alpha_n \in prob_amp$ при $n \in [0, 1, qudit_len - 1]$ в вероятности существования состояний кудита $Pr_n = |\alpha_n|^2$.
13. $qcv_{ij\psi} \leftarrow qcv_{ij\psi} \cup prob_amp$ ▷ добавить кортеж $prob_amp$ в конец кортежа $qcv_{ij\psi}$.
14. **Если** $h_prob > Pr_n \in prob_amp$ **выполнить:**
15. $a_n \in ccv_{ij\psi} \leftarrow 1$ ▷ установить значение 1 для соответствующего элемента a в кортеже $ccv_{ij\psi}$.
16. **Преобразовать** кортеж бинарных значений $ccv_{ij\psi}$ в число a_ψ в 10-й системе счисления и **сохранить** результат в d_ccv_{ij}.
17. **Завершить цикл.**
18. **Возвратить** $qcv_{ij\psi}$, $ccv_{ij\psi}$, d_ccv_{ij} ▷ кортежи хромосом.

Алгоритм 3

Инициализация генов квантовой популяции

Вход: $pop_size \in \mathbb{N}$ ▷ размер квантовой популяции.

$chrom_len \in \mathbb{N}$ ▷ длина квантовой хромосомы.

$qudit_len \in \mathbb{N}$ ▷ длина кудита.

$\theta = \varnothing$ ▷ кортеж углов поворота состояний квантовых генов $|\psi\rangle_1 \ldots |\psi\rangle_{chrom_len}$.

$\tau = 0{,}01$ ▷ уровень ошибки, по умолчанию устанавливается значение 0,01.

$qcv = \langle\langle\langle\langle Pr_n\rangle_\psi\rangle_j\rangle_i$: $j \in [0, 1, chrom_len - 1]$; $i \in [0, 1, pop_size - 1]$; $\psi, n \in [0, 1, qudit_len - 1]\rangle$ ▷ вектор квантовых хромосом, представляет собой кортеж кортежей с кортежами кортежей, содержащими нулевые значения вероятностей Pr.

$ccv = \langle\langle\langle\langle a_n\rangle_\psi\rangle_j\rangle_i$: $j \in [0, 1, chrom_len - 1]$; $i \in [0, 1, pop_size - 1]$; $\psi, n \in [0, 1, qudit_len - 1]\rangle$ ▷ вектор классических хромосом, представляет собой кортеж кортежей с кортежами кортежей, содержащими нулевые значения a результатов измерения состояний квантовых хромосом qcv.

$qudit_state = \langle|\psi\rangle$: $\psi \in [0, 1, qudit_len - 1]\rangle$ ▷ кортеж состояний кудита длины $qudit_len$.

1. $z = \langle(qudit_len^2 - 1)/2, (qudit_len^2 + 2)/2\rangle$ ▷ кортеж размерностей пространства выполнения квантовых операций.
2. **Для каждого** $i \in [1, 2, pop_size]$ **выполнять:**
3. **Для каждого** $j \in [1, 2, chrom_len]$ **выполнять:**
4. **Если** $qudit_len \in \mathbb{P}$ **выполнить:**
5. **Для каждого** $n \in [1, 2, z_0]$ **выполнять:**
6. $\theta \leftarrow \theta \cup (\tau N(0, 1)_n)$ ▷ добавить в конец кортежа θ угол поворота в пространстве $\mathbb{R}^{z_0}$.
7. **Завершить цикл.**
8. $qcv, ccv, d_ccv \leftarrow$ **Алгоритм 2** ($pop_size, chrom_len, qudit_len, \theta, qcv, ccv, qudit_state$).
9. **Иначе выполнить:**
10. **Для каждого** $n \in [1, 2, z_1]$ **выполнять:**
11. $\theta \leftarrow \theta \cup (\tau N(0, 1)_n)$ ▷ добавить в конец кортежа θ угол поворота в пространстве $\mathbb{R}^{z_1}$.
12. **Завершить цикл.**
13. $qcv, ccv, d_ccv \leftarrow$ **Алгоритм 2** ($pop_size, chrom_len, qudit_len, \theta, qcv, ccv, qudit_state$).
14. **Завершить цикл.**
15. **Завершить цикл.**
16. **Возвратить** qcv, ccv, d_ccv ▷ кортежи хромосом.

Следующий шаг выполнения модифицированного алгоритма – оценка функции приспособленности (алгоритм 4). Поскольку входные значения оптимизируемых функций в существующих разновидностях генетических алгоритмов квантово-инспирированного типа [17; 23; 29] являются зависимыми от количества хромосом в квантовой популяции, а также от количества генов в хромосомах, в текущем алгоритме осуществляется проверка принадлежности значений генов классических хромосом в кортеже d_ccv диапазону значений X функции приспособленности для поиска глобального максимума. В случае отсутствия принадлежности данные значения в кортеже d_ccv заменяются на случайные значения из диапазона X, при этом отсутствующие в кортеже d_ccv. Далее определяются среднее и суммарное значения функции приспособленности, а также порядковый номер лучшей хромосомы в квантовой популяции.

В модифицированном квантово-инспирированном генетическом алгоритме роль оператора скрещивания (алгоритм 6) выполняют квантовые вентили вращения состояний квантовых генов на сферообразной геометрической конструкции Блоха для кудитов (9). Первоначально, если значение в кортеже *fit* по индексу размера квантовой популяции меньше значения в кортеже *fit* по индексу порядкового номера лучшей хромосомы в квантовой популяции, установленного на этапе оценки функции приспособленности, то по аналогии с алгоритмом 3 определяется размерность пространства $\mathbb{R}$ выполнения квантовых операций и вычисляются углы поворота θ состояний квантовых генов, но со смещением Δ. Вслед за этим для каждого квантового состояния $|\psi\rangle$ кудита в зависимости от бинарных значений генов классических хромосом в кортеже ccv вычисляются эрмитовы матрицы и на их основе матрица плотности ρ (алгоритм 5). Далее рассчитываются обновленные вероятности существования состояний кудита n_ccv как произведение матрицы плотности ρ и исходных вероятностей существования состояний кудита qcv. Затем происходит обновление qcv путем вычитания из единицы n_qcv.

Алгоритм 4

Оценка функции приспособленности

Вход: $pop_size \in \mathbb{N}$ ▷ размер квантовой популяции.

$chrom_len \in \mathbb{N}$ ▷ длина квантовой хромосомы.

$gen_num \in \mathbb{N}$ ▷ номер поколения (итерации).

$gen_max \in \mathbb{N}$ ▷ максимальное число поколений (итераций).

$qudit_len \in \mathbb{N}$ ▷ длина кудита.

d_ccv ▷ вектор классических хромосом.

$b_chrom = \langle g_i : i \in [0, 1, gen_max - 1]\rangle$ ▷ кортеж с нулевыми значениями g размера gen_max.

$fit = \langle p_i : i \in [0, 1, pop_size - 1]\rangle$ ▷ кортеж с нулевыми значениями p размера pop_size.

$fit_total = 0$ ▷ переменная для накопления суммы.

1. **Для каждого** $i \in [1, 2, pop_size]$ **выполнять:**
2. $sum = \langle q_i : i \in [0, 1, chrom_len - 1]$ ▷ кортеж с нулевыми значениями q размера $chrom_len$.
3. **Для каждого** $j \in [1, 2, chrom_len]$ **выполнять:**
4. **Если** $a_\psi \notin X$ **выполнить:** ▷ проверить принадлежность элементов $a_\psi \in d_ccv_{ij}$ при $\psi \in [0, 1, qudit_len - 1]$ диапазону значений X для поиска глобального максимума $\max(f(sum))$ выбранной функции для оптимизации.
5. $\mathrm{del}\,(a_\psi)$ ▷ удалить элемент из кортежа d_ccv_{ij}.
6. $d_ccv_{ij} \leftarrow d_ccv_{ij} \cup (b_\psi \in X)$ ▷ добавить в кортеж d_ccv_{ij} элемент b_ψ (отсутствующий в d_ccv_{ij}) из диапазона значений X.
7. $sum \leftarrow sum + d_ccv_{ij}$ ▷ сложить кортежи и перезаписать результат в sum.
8. $fit_i \leftarrow f(sum)*100$ ▷ передать аргумент sum в функцию для оптимизации $f(sum)$ и сохранить результат в fit_i.
9. **Завершить цикл.**
10. $fit_total \leftarrow fit_total + fit_i$ ▷ добавить результат вычисления fit_i в fit_total.
11. **Завершить цикл.**
12. $fit_avg = fit_total/pop_size$ ▷ определить среднее значение относительно всех значений в fit.
13. $fit_max = fit_1$ ▷ установить максимальное значение fit.
14. $b_chrom_num = 0$ ▷ порядковый номер лучшей хромосомы в квантовой популяции.
15. **Для каждого** $i \in [1, 2, pop_size]$ **выполнять:**
16. **Если** $fit_i \geq fit_max$ **выполнить:**
17. $fit_max \leftarrow fit_i$ ▷ переопределить fit_max.
18. $b_chrom_num \leftarrow i$ ▷ переопределить b_chrom_num.
19. **Завершить цикл.**
20. $b_chrom_{gen_num} \leftarrow b_chrom_num$ ▷ записать b_chrom_num в кортеж b_chrom по индексу gen_num.
21. **Возвратить** fit_avg, fit_total, $b_chrom_{gen_num}$ ▷ среднее значение, суммарное значение функции приспособленности и порядковый номер лучшей хромосомы в квантовой популяции.

Алгоритм 5

Вычисление обновленных квантовых хромосом

Вход: $pop_size \in \mathbb{N}$ ▷ размер квантовой популяции.

$chrom_len \in \mathbb{N}$ ▷ длина квантовой хромосомы.

$qudit_len \in \mathbb{N}$ ▷ длина кудита.

$\Delta\theta \in \mathbb{R}$ ▷ кортеж углов поворота со смещением Δ состояний квантовых генов $|\psi\rangle_1 \ldots |\psi\rangle_{chrom_len}$.

$qcv = \langle\langle\langle\langle Pr_n\rangle_\psi\rangle_j\rangle_i : j \in [0, 1, chrom_len - 1];\ i \in [0, 1, pop_size - 1];\ \psi, n \in [0, 1, qudit_len - 1]\rangle$ ▷ вектор квантовых хромосом.

1. $z = \langle (qudit_len^2 - 1)/2, (qudit_len^2 + 2)/2\rangle$ ▷ кортеж размерностей пространства выполнения квантовых операций.
2. $n_qcv = qcv$ ▷ копия вектора квантовых хромосом qcv.

3. $i \in [1, 2, pop_size]$ ▷ номер итерации относительно *pop_size*.
4. $j \in [1, 2, chrom_len]$ ▷ номер итерации относительно *chrom_len*.
5. $\psi \in [0, 1, qudit_len - 1]$ ▷ состояние кудита.
6. $H = \varnothing$ ▷ кортеж эрмитовых матриц.
7. $A = \left((-1)^{\frac{p(2-q)}{qudit_len}} \left(e^{i\theta_m} \left| p \right\rangle \left| (q+1) \bmod qudit_len \right\rangle + e^{-i\theta_m} \left| p \right\rangle \left| (q+1) \bmod qudit_len \right\rangle \right) \right)$ ▷ вычислить эрмитовы матрицы $A \sim A_m$ при $\theta_m \in \Delta\theta$; $m \in [1, 2, z]$; $p,\ q = \overline{0,\ qudit_len - 1}$ с учетом свойства $\rho^\dagger = \rho$.
8. $H \leftarrow H \cup A$ ▷ последовательно добавить эрмитовы матрицы A в конец кортежа H.
9. $\rho = \frac{1}{qudit_len} \left(E + \frac{1}{2} \sum_{m=1}^{z} \mathrm{tr}\left(\rho H_m\right) H_m \right)$ ▷ вычислить матрицу плотности ρ при $H_m \in H$.
10. $n_qcv_{ij\psi} \leftarrow qcv_{ij\psi}\rho$ ▷ вычислить новые вероятности существования состояний кудита и сохранить результат в $n_qcv_{ij\psi}$.
11. $qcv_{ij\psi} \leftarrow 1 - n_qcv_{ij\psi}$ ▷ обновить $qcv_{ij\psi}$.
12. **Возвратить** $qcv_{ij\psi}$, $n_qcv_{ij\psi}$ ▷ кортежи хромосом.

Алгоритм 6

Операция скрещивания

Вход: $pop_size \in \mathbb{N}$ ▷ размер квантовой популяции.

$chrom_len \in \mathbb{N}$ ▷ длина квантовой хромосомы.

$gen_num \in \mathbb{N}$ ▷ номер поколения (итерации).

$gen_max \in \mathbb{N}$ ▷ максимальное число поколений (итераций).

$qudit_len \in \mathbb{N}$ ▷ длина кудита.

$qcv = \langle\langle\langle\langle Pr_n \rangle_\psi \rangle_j \rangle_i : j \in [0, 1, chrom_len - 1];\ i \in [0, 1, pop_size - 1];\ \psi, n \in [0, 1, qudit_len - 1]\rangle$ ▷ вектор квантовых хромосом.

$ccv = \langle\langle\langle\langle a_n \rangle_\psi \rangle_j \rangle_i : j \in [0, 1, chrom_len - 1];\ i \in [0, 1, pop_size - 1];\ \psi, n \in [0, 1, qudit_len - 1]\rangle$ ▷ вектор классических хромосом.

$b_chrom = \langle g_i : i \in [0, 1, gen_max - 1]\rangle$ ▷ кортеж порядковых номеров лучших хромосом.

1. $z = \langle (qudit_len^2 - 1)/2, (qudit_len^2 + 2)/2 \rangle$ ▷ кортеж размерностей пространства выполнения квантовых операций.
2. **Для каждого** $i \in [1, pop_size]$ **выполнять:**
3. **Для каждого** $j \in [1, chrom_len]$ **выполнять:**
4. **Если** $fit_i < fit_{b_chrom_{gen_num}}$ **выполнить:**
5. **Если** $qudit_len \in \mathrm{P}$ **выполнить:**
6. **Для каждого** $m \in [1, 2, z_0]$ **выполнять:**
7. $\Delta\theta \leftarrow \Delta\theta \cup \theta_m$ ▷ добавить в конец кортежа $\Delta\theta$ угол поворота θ_m со смещением Δ в пространстве $\mathbb{R}^{z_0}$.
8. **Завершить цикл.**
9. **Для каждого** $\psi \in [0, 1, qudit_len - 1]$ **выполнять:**
10. **Если** $ccv_{ij\psi} = 0$ и $ccv_{b_chrom_{gen_num}j\psi} = 1$ **выполнить:**
11. $qcv_{ij\psi}$, $n_qcv_{ij\psi} \leftarrow$ **Алгоритм 5** (*pop_size*, *chrom_len*, *qudit_len*, $\Delta\theta$, *qcv*).
12. **Если** $ccv_{ij\psi} = 1$ и $ccv_{b_chrom_{gen_num}j\psi} = 0$ **выполнить:**
13. $qcv_{ij\psi}$, $n_qcv_{ij\psi} \leftarrow$ **Алгоритм 5** (*pop_size*, *chrom_len*, *qudit_len*, $\Delta\theta$, *qcv*) ▷ при $-\theta_m \in \Delta\theta$.
14. **Завершить цикл.**
15. **Иначе выполнить:**
16. **Для каждого** $m \in [1, 2, z_1]$ **выполнять:**
17. $\Delta\theta \leftarrow \Delta\theta \cup \theta_m$ ▷ добавить в конец кортежа $\Delta\theta$ угол поворота θ_m со смещением Δ в пространстве $\mathbb{R}^{z_1}$.
18. **Завершить цикл.**
19. **Для каждого** $\psi \in [0, 1, qudit_len - 1]$ **выполнять:**

Если $ccv_{ij\psi} = 0$ и $ccv_{b_chrom_{gen_num}j\psi} = 1$ **выполнить:**
$qcv_{ij\psi}$, $n_qcv_{ij\psi} \leftarrow$ **Алгоритм 5** (*pop_size*, *chrom_len*, *qudit_len*, $\Delta\theta$, *qcv*).
Если $ccv_{ij\psi} = 1$ и $ccv_{b_chrom_{gen_num}j\psi} = 0$ **выполнить:**
$qcv_{ij\psi}$, $n_qcv_{ij\psi} \leftarrow$ **Алгоритм 5** (*pop_size*, *chrom_len*, *qudit_len*, $\Delta\theta$, *qcv*) ▷ при $-\theta_m \in \Delta\theta$.
Завершить цикл.
Завершить цикл.
Завершить цикл.
Возвратить *qcv*, *n_qcv* ▷ кортежи хромосом.

Следующим и заключительным этапом модифицированного алгоритма является операция мутации (алгоритм 7). Для выполнения данной операции задаются значения показателей частоты *pop_mut* и вероятности *mut_prob* мутации в популяции. Далее вычисляется пороговое значение частоты мутации *ub_pop* и в том случае, если оно меньше либо равняется заданному значению показателя частоты мутации *pop_mut*, вычисляется пороговое значение вероятности мутации *ub_mut*. Затем для каждого состояния $|\psi\rangle$ кудита проверяется выполнение условия того, что пороговое значение вероятности мутации *ub_mut* меньше либо равняется заданному значению показателя вероятности мутации *mut_prob*. В случае выполнения условия обновляется вектор квантовых хромосом *n_qcv* присвоением ему вектора квантовых хромосом *qcv* с записью ψ-х элементов вектора *qcv* в обратном порядке. Если данное условие не выполняется, то вектор квантовых хромосом *n_qcv* обновляется обычным присвоением ему вектора квантовых хромосом *qcv*. При невыполнении условия *ub_pop* ≤ *pop_mut* для каждого состояния $|\psi\rangle$ кудита также выполняется обновление вектора квантовых хромосом *n_qcv* присвоением ему вектора квантовых хромосом *qcv*. В завершении операции мутации для каждого состояния $|\psi\rangle$ кудита обновляется вектор квантовых хромосом *qcv* присвоением ему вектора квантовых хромосом *n_qcv*.

Полный псевдокод модифицированного квантово-инспирированного алгоритма численной оптимизации приведен в алгоритме 8.

Алгоритм 7

Операция мутации

Вход: *pop_size* ∈ ℕ ▷ размер квантовой популяции.
chrom_len ∈ ℕ ▷ длина квантовой хромосомы.
qudit_len ∈ ℕ ▷ длина кудита.
$qcv = \langle\langle\langle\langle Pr_n\rangle_\psi\rangle_j\rangle_i$: $j \in [0, 1, chrom_len - 1]$; $i \in [0, 1, pop_size - 1]$; $\psi, n \in [0, 1, qudit_len - 1]\rangle$ ▷ вектор квантовых хромосом.
pop_mut = 0,01 ▷ частота мутации в популяции, по умолчанию устанавливается значение 0,01.
mut_prob = 0,001 ▷ вероятность мутации, по умолчанию устанавливается значение 0,001.
n_qcv = *qcv* ▷ копия вектора квантовых хромосом *qcv*.
Для каждого $i \in [1, 2, pop_size]$ **выполнять:**
ub_pop = *x*/100 ▷ пороговое значение частоты мутации, где *x* – случайное число при $\forall x \in [1, 100]$.
Если *ub_pop* ≤ *pop_mut* **выполнить:**
Для каждого $j \in [1, 2, chrom_len]$ **выполнять:**
ub_mut = *y*/100 ▷ пороговое значение вероятности мутации, где *y* – случайное число при $\forall y \in [1, 100]$.
Для каждого $\psi \in [0, 1, qudit_len - 1]$ **выполнять:**
Если *ub_mut* ≤ *mut_prob* **выполнить:**
$n_qcv_{ij\psi} \leftarrow qcv_{ij\tilde{\psi}}$ ▷ обновить $n_qcv_{ij\psi}$, при $\tilde{\psi} \in [qudit_len - 1, qudit_len - 2, 0]$.
Иначе выполнить:
$n_qcv_{ij\psi} \leftarrow qcv_{ij\psi}$ ▷ обновить $n_qcv_{ij\psi}$.
Завершить цикл.
Завершить цикл.
Иначе выполнить:
Для каждого $j \in [1, 2, chrom_len]$ **выполнять:**
Для каждого $\psi \in [0, 1, qudit_len - 1]$ **выполнять:**
$n_qcv_{ij\psi} \leftarrow qcv_{ij\psi}$ ▷ обновить $n_qcv_{ij\psi}$.
Завершить цикл.

19. **Завершить цикл.**
20. **Завершить цикл.**
21. **Для каждого** $i \in [1, 2, pop_size]$ **выполнять:**
22. **Для каждого** $j \in [1, 2, chrom_len]$ **выполнять:**
23. **Для каждого** $\psi \in [0, 1, qudit_len - 1]$ **выполнять:**
24. $qcv_{ij\psi} \leftarrow n_qcv_{ij\psi}$ ▷ обновить $qcv_{ij\psi}$.
25. **Завершить цикл.**
26. **Завершить цикл.**
27. **Завершить цикл.**
28. **Возвратить** *qcv*, *n_qcv* ▷ кортежи хромосом.

Алгоритм 8

Модифицированный квантово-инспирированный генетический алгоритм численной оптимизации

Вход: $pop_size \in \mathbb{N}$ ▷ размер квантовой популяции.

$chrom_len \in \mathbb{N}$ ▷ длина квантовой хромосомы.

$gen_num \in 0$ ▷ номер поколения (итерации).

$gen_max \in \mathbb{N}$ ▷ максимальное число поколений (итераций).

$qudit_len \in \mathbb{N}$ ▷ длина кудита.

$\theta = \varnothing$ ▷ кортеж углов поворота состояний квантовых генов $|\psi\rangle_1 \ldots |\psi\rangle_{chrom_len}$.

$\Delta\theta = \varnothing$ ▷ кортеж углов поворота со смещением Δ состояний квантовых генов $|\psi\rangle_1 \ldots |\psi\rangle_{chrom_len}$.

$\tau = 0{,}01$ ▷ уровень ошибки, по умолчанию устанавливается значение 0,01.

$qcv = \langle\langle\langle\langle Pr_n\rangle_\psi\rangle_j\rangle_i$: $j \in [0, 1, chrom_len - 1]$; $i \in [0, 1, pop_size - 1]$; $\psi, n \in [0, 1, qudit_len - 1]\rangle$ ▷ вектор квантовых хромосом, представляет собой кортеж кортежей с кортежами кортежей, содержащими нулевые значения вероятностей *Pr*.

$ccv = \langle\langle\langle\langle a_n\rangle_\psi\rangle_j\rangle_i$: $j \in [0, 1, chrom_len - 1]$; $i \in [0, 1, pop_size - 1]$; $\psi, n \in [0, 1, qudit_len - 1]\rangle >$ вектор классических хромосом, представляет собой кортеж кортежей с кортежами кортежей, содержащими нулевые значения *a* результатов измерения состояний квантовых хромосом *qcv*.

$b_chrom = \langle g_i: i \in [0, 1, gen_max - 1]\rangle$ ▷ кортеж с нулевыми значениями размера *gen_max*.

$qudit_state = \langle|\psi\rangle: \psi \in [0, 1, qudit_len - 1]\rangle$ ▷ кортеж состояний кудита длины *qudit_len*.

$pop_mut = 0{,}01$ ▷ частота мутации в популяции, по умолчанию устанавливается значение 0,01.

$mut_prob = 0{,}001$ ▷ вероятность мутации, по умолчанию устанавливается значение 0,001.

1. $z = \langle(qudit_len^2 - 1)/2, (qudit_len^2 + 2)/2\rangle$ ▷ кортеж размерностей пространства выполнения квантовых операций.
2. $n_qcv = qcv$ ▷ копия вектора квантовых хромосом *qcv*.
3. $d_ccv = ccv$ ▷ копия вектора классических хромосом *ccv*.
4. $h_prob = \left(\frac{1}{\sqrt{qudit_len}}\right)^2$ ▷ значение вероятности существования состояния $|0\rangle$ кудита в условии неопределенности.
5. **Для каждого** $i \in [1, 2, pop_size]$ **выполнять:**
6. **Для каждого** $j \in [1, 2, chrom_len]$ **выполнять:**
7. **Если** $qudit_len \in \mathbb{P}$ **выполнить:**
8. **Для каждого** $n \in [1, 2, z_0]$ **выполнять:**
9. $\theta \leftarrow \theta \cup (\tau N(0, 1)_n)$ ▷ добавить в конец кортежа θ угол поворота в пространстве $\mathbb{R}^{z_0}$.
10. **Завершить цикл.**
11. *qcv*, *ccv*, *d_ccv* ← **Алгоритм 2** (*pop_size*, *chrom_len*, *qudit_len*, θ, *qcv*, *ccv*, *qudit_state*).
12. **Иначе выполнить:**
13. **Для каждого** $n \in [1, 2, z_1]$ **выполнять:**
14. $\theta \leftarrow \theta \cup (\tau N(0, 1)_n)$ ▷ добавить в конец кортежа θ угол поворота в пространстве $\mathbb{R}^{z_1}$.
15. **Завершить цикл.**
16. *qcv*, *ccv*, *d_ccv* ← **Алгоритм 2** (*pop_size*, *chrom_len*, *qudit_len*, θ, *qcv*, *ccv*, *qudit_state*).

17. **Завершить цикл.**
18. **Завершить цикл.**
19. *fit_avg*, *fit_total*, $b_chrom_{gen_num}$ ← **Алгоритм 4** (*pop_size*, *chrom_len*, *gen_num*, *gen_max*, *qudit_len*, *d_ccv*, *b_chrom*, *fit*, *fit_total*).
20. **Пока** *gen_num* < *gen_max* – 1 **выполнять:**
21. *qcv*, *n_qcv* ← **Алгоритм 6** (*pop_size*, *chrom_len*, *gen_num*, *gen_max*, *qudit_len*, *qcv*, *ccv*, *b_chrom*).
22. *qcv*, *n_qcv* ← **Алгоритм 7** (*pop_size*, *chrom_len*, *qudit_len*, *qcv*, *pop_mut*, *mut_prob*).
23. *gen_num* ← *gen_num* + 1 ▷ обновить значение *gen_num*.
24. **Для каждого** $i \in [1, 2, pop_size]$ **выполнять:**
25. **Для каждого** $j \in [1, 2, chrom_len]$ **выполнять:**
26. **Для каждого** $\psi \in [0, 1, qudit_len - 1]$ **выполнять:**
27. **Если** $h_prob > qcv_{ij\psi}$ **выполнить:**
28. $a_n \in ccv_{ij\psi} \leftarrow 1$ ▷ установить значение 1 для соответствующего элемента *a* в кортеже $ccv_{ij\psi}$ при $n \in [0, 1, qudit_len - 1]$.
29. **Иначе выполнить:**
30. $a_n \in ccv_{ij\psi} \leftarrow 0$ ▷ установить значение 0 для соответствующего элемента *a* в кортеже $ccv_{ij\psi}$ при $n \in [0, 1, qudit_len - 1]$.
31. **Завершить цикл.**
32. **Завершить цикл.**
33. **Завершить цикл.**
34. *fit_avg*, *fit_total*, $b_chrom_{gen_num}$ ← **Алгоритм 4** (*pop_size*, *chrom_len*, *gen_num*, *gen_max*, *qudit_len*, *d_ccv*, *b_chrom*, *fit*, *fit_total*).
35. **Завершить цикл.**
36. **Возвратить** лучшее решение, найденное в процессе эволюции.

2.3. Тестирование модифицированного квантово-инспирированного генетического алгоритма численной оптимизации

Определение качества работы модифицированного квантово-инспирированного генетического алгоритма (Modified Quantum-Inspired Genetic Algorithm, MQIGA) осуществляется путем сравнительного анализа лучших значений, среднего арифметического и среднеквадратического отклонения лучших результатов вычислений оптимизируемых функций (в течение всех запусков алгоритма), среднего времени выполнения модифицированного алгоритма MQIGA с аналогичными характеристиками обычного квантово-инспирированного генетического алгоритма (Quantum-Inspired Genetic Algorithm, QIGA) [16] и набора классических популяционных алгоритмов как на функциях тестовых задач оптимизации, так и при решении практической задачи в области планирования производства в обрабатывающей промышленности. Кроме этого, отдельное внимание уделяется оценке качества алгоритма MQIGA при его использовании для решения задачи повышения точности прогнозирования на основе компактных машин экстремального обучения. По результатам тестирования для каждого алгоритма выполняется визуализация графиков сходимости для оптимизируемых функций [7]. Также оценка качества работы модифицированного алгоритма MQIGA дополнительно проводится за счет непараметрического статистического теста Уилкоксона [13].

Все последующие этапы тестирования выполняются в интерактивной среде разработки JupyterLab на базе вычислительного устройства с процессором Intel Core i9-13980HX и объемом оперативной памяти 32 Гб.

Популяционные алгоритмы оптимизации взяты из библиотеки mealpy [31], реализованной на высокоуровневом языке программирования Python, и содержащей в себе большое количество метаэвристических алгоритмов, которые являются наиболее распространенными алгоритмами в области приближенной оптимизации. Для тестирования выбраны классический генетический алгоритм (Genetic Algorithm, GA), дифференциальная эволюция (Differential Evolution, DE), метод роя частиц (Particle Swarm Optimization, PSO) и оптимизация методом ядерной реакции (Nuclear Reaction Optimization, NRO).

В табл. 1 приведен набор из восьми тестовых оптимизируемых функций [11]. Необходимо отметить, что в связи с поиском глобального максимума функций, решение исходной задачи минимизации превращается в решение задачи максимизации, то есть соблюдается условие $\arg\min f(\bar{x}) = \arg\max(-f(\bar{x}))$ при $\bar{x} \in \mathbb{R}$. При этом в отличие от функций $f_1 - f_7$, имеющих фиксированный глобальный максимум в точке 0, максимальное значение функции f_8 изменяется в соответствии с ее размерностью *n*.

Таблица 1

Тестовые функции, используемые для оптимизации [Test functions used for optimization]

Название [Name]	Формула [Formula]	Диапазон поиска [Search range]	Глобальный максимум [Global maximum]
Функция Растригина [Rastrigin function]	$f_1(\bar{x}) = 10n + \sum_{i=1}^{n}\left(x_i^2 - 10\cos(2\pi x_i)\right)$	$-5{,}12 \le x_i \le 5{,}12$	0
Функция сферы [Sphere function]	$f_2(\bar{x}) = \sum_{i=1}^{n} x_i^2$	$-100 \le x_i \le 100$	0
Функция Гриванка [Griewank function]	$f_3(\bar{x}) = 1 + \sum_{i=1}^{n}\frac{x_i^2}{4000} - \prod_{i=1}^{n}\cos\left(\frac{x_i}{\sqrt{i}}\right)$	$-100 \le x_i \le 100$	0
Функция Швефеля 1.2 [Schwefel function 1.2]	$f_4(\bar{x}) = \sum_{i=1}^{n}\left(\sum_{j=1}^{i} x_j\right)^2$	$-100 \le x_i \le 100$	0
Функция Экли [Ackley function]	$f_5(\bar{x}) = -20\exp\left(-0{,}2\sqrt{\frac{1}{n}\sum_{i=1}^{n}x_i^2}\right) - \exp\left(\frac{1}{n}\sum_{i=1}^{n}\cos(2\pi x_i)\right) + e + 20$	$-32{,}7 \le x_i \le 32{,}7$	0
Функция Розенброка [Rosenbrock function]	$f_6(\bar{x}) = \sum_{i=1}^{n-1}\left(100\left(x_{i+1} - x_i^2\right)^2 + \left(x_i - 1\right)^2\right)$	$-10 \le x_i \le 10$	0
Функция Захарова [Zakharov function]	$f_7(\bar{x}) = \sum_{i=1}^{n}x_i^2 + \left(\sum_{i=1}^{n}0{,}5ix_i\right)^2 + \left(\sum_{i=1}^{n}0{,}5ix_i\right)^4$	$-10 \le x_i \le 10$	0
Функция Стыбинского–Танга [Styblinski–Tang function]	$f_8(\bar{x}) = \frac{\sum_{i=1}^{n}x_i^4 - 16x_i^2 + 5x_i}{2}$	$-5 \le x_i \le 5$	$39{,}1659n$

Размер популяции для всех оптимизационных алгоритмов, участвующих в тестировании, устанавливается равным 100, а максимальное значение итераций – 450. Запуск процесса оптимизации повторяется 50 раз. При этом рассматриваемые алгоритмы имеют следующие настройки своих специфицированных параметров.

1. MQIGA: длина квантовой хромосомы – 4, длина кудита – 5, уровень ошибки – 0.01, частота мутации – 0,01, вероятность мутации – 0,05.
2. QIGA: длина квантовой хромосомы – 4, частота мутации – 0,01, вероятность мутации – 0,05.
3. GA: вероятность скрещивания – 0,95, вероятность мутации – 0,05.
4. DE: весовой коэффициент – 0,7, частота скрещивания – 0,9.
5. PSO: локальный коэффициент – 2,05, глобальный коэффициент – 2,05.
6. NRO: дополнительные параметры отсутствуют.

В табл. 2 и 3 представлены результаты выполнения алгоритмов оптимизации на тестовых функциях размерности $n = 2$ и $n = 15$ соответственно, где показатель b – лучшее значение оптимизируемой функции, μ – среднее арифметическое лучших результатов вычислений оптимизируемой функции всех запусков алгоритма, σ – среднеквадратическое отклонение результатов вычислений оптимизируемой функции всех запусков алгоритма, t – среднее время, затрачиваемое на выполнение алгоритма с первой и до последней итерации. Полужирным начертанием указываются те значения показателей, которые приближены к целевым значениям или совпадают с ними.

В табл. 4 и 5 представлены результаты непараметрического статистического теста Уилкоксона, применяемого к распределению наилучших значений оптимизируемых тестовых функций размерности $n = 2$ и $n = 15$ соответственно, найденных алгоритмом MQIGA, и распределениям значений, полученным для алгоритмов QIGA, GA, DE, PSO, NRO. Пороговое значение p-value устанавливается равным 0,05.

Выполнение алгоритмов оптимизации на тестовых функциях размерности $n = 2$ (см. табл. 2) показывает, что оптимизация алгоритмом MQIGA достигает одинаковых значений показателей b, μ, σ для функций $f_1 - f_7$ в точке глобального максимума наравне с алгоритмом NRO. Для функции f_8 все алгоритмы находят одинаковый наиболее приближенный к целевому значению b глобальный максимум и только алгоритм GA наиболее точно определяет значение μ.

Таблица 2

Результаты выполнения алгоритмов оптимизации на тестовых функциях размерности *n* = 2
[Results of executing optimization algorithms on test functions of dimension *n* = 2]

Функция [Function]	Показатель [Indicator]	MQIGA	QIGA	GA	DE	PSO	NRO
f_1	*b*	**–0,0000**	**–0,0000**	–0,0001	**–0,0000**	**–0,0000**	**–0,0000**
	μ	**–0,0000**	**–0,0000**	–0,0059	**–0,0000**	**–0,0000**	**–0,0000**
	σ	**0,0000**	**0,0000**	0,0107	**0,0000**	**0,0000**	**0,0000**
	t	1,2489	1,9239	2,4763	**1,2343**	1,4393	7,3381
f_2	*b*	**–0,0000**	**–0,0000**	**–0,0000**	**–0,0000**	**–0,0000**	**–0,0000**
	μ	**–0,0000**	**–0,0000**	–0,0080	**–0,0000**	**–0,0000**	**–0,0000**
	σ	**0,0000**	**0,0000**	0,0096	**0,0000**	**0,0000**	**0,0000**
	t	**1,1932**	1,9348	2,5123	1,3377	1,2184	7,4269
f_3	*b*	**–0,0000**	**–0,0000**	**–0,0000**	**–0,0000**	**–0,0000**	**–0,0000**
	μ	**–0,0000**	**–0,0000**	–0,0055	–0,0004	–0,0025	**–0,0000**
	σ	**0,0000**	**0,0000**	0,0038	0,0018	0,0035	**0,0000**
	t	1,1848	1,4240	2,6667	**1,1631**	1,2007	7,5944
f_4	*b*	**–0,0000**	**–0,0000**	**–0,0000**	**–0,0000**	**–0,0000**	**–0,0000**
	μ	**–0,0000**	**–0,0000**	–0,0028	**–0,0000**	**–0,0000**	**–0,0000**
	σ	**0,0000**	**0,0000**	0,0065	**0,0000**	**0,0000**	**0,0000**
	t	**1,0293**	1,0803	1,9140	1,3416	1,2947	7,0501
f_5	*b*	**–0,0000**	**–0,0000**	–0,0094	**–0,0000**	**–0,0000**	**–0,0000**
	μ	**–0,0000**	**–0,0000**	–0,1129	**–0,0000**	**–0,0000**	**–0,0000**
	σ	**0,0000**	**0,0000**	0,1222	**0,0000**	**0,0000**	**0,0000**
	t	1,4012	1,5154	2,7328	1,5174	**1,2880**	7,3857
f_6	*b*	**–0,0000**	**–0,0000**	–0,0002	**–0,0000**	**–0,0000**	**–0,0000**
	μ	**–0,0000**	–0,0023	–0,5932	**–0,0000**	**–0,0000**	**–0,0000**
	σ	**0,0000**	0,0042	0,7993	**0,0000**	**0,0000**	**0,0000**
	t	1,1710	1,9703	3,2147	1,1791	**1,1451**	7,7113
f_7	*b*	**–0,0000**	**–0,0000**	**–0,0000**	**–0,0000**	**–0,0000**	**–0,0000**
	μ	**–0,0000**	**–0,0000**	–0,0002	**–0,0000**	**–0,0000**	**–0,0000**
	σ	**0,0000**	**0,0000**	0,0002	**0,0000**	**0,0000**	**0,0000**
	t	**1,0036**	1,4734	2,0839	1,4891	1,3500	7,1404
f_8	*b*	**78,3323**	**78,3323**	**78,3323**	**78,3323**	**78,3323**	**78,3323**
	μ	78,3323	78,3323	**78,3318**	78,3323	78,3323	78,3323
	σ	**0,0000**	**0,0000**	0,0007	**0,0000**	**0,0000**	**0,0000**
	t	1,1895	1,8152	2,5784	1,3252	**1,1479**	7,6730

Таблица 3

Результаты выполнения алгоритмов оптимизации на тестовых функциях размерности *n* = 15
[Results of executing optimization algorithms on test functions of dimension *n* = 15]

Функция [Function]	Показатель [Indicator]	MQIGA	QIGA	GA	DE	PSO	NRO
f_1	*b*	**–0,0000**	**–0,0000**	–0,0378	–66,7216	–8,9546	**–0,0000**
	μ	**–0,0000**	**–0,0000**	–0,1684	–86,9338	–25,2406	**–0,0000**
	σ	**0,0000**	**0,0000**	0,0986	7,9157	8,2207	**0,0000**
	t	**1,4751**	2,5311	3,2686	1,7510	1,6266	8,4771
f_2	*b*	**–0,0000**	**–0,0000**	−0,0595	−0,7820	**–0,0000**	**–0,0000**
	μ	**–0,0000**	**–0,0000**	−0,3018	−1,9063	**–0,0000**	**–0,0000**
	σ	**0,0000**	**0,0000**	0,1452	0,6956	**0,0000**	**0,0000**
	t	**1,2862**	2,2497	2,8221	1,2984	1,3176	8,8391
f_3	*b*	**–0,0000**	**–0,0000**	−0,0096	−0,3796	**–0,0000**	**–0,0000**
	μ	−0,0005	**–0,0000**	–0,0055	−0,6860	−0,1134	**–0,0000**
	σ	0,0012	**0,0000**	0,0295	0,0932	0,1315	**0,0000**
	t	**1,5061**	2,5780	3,0456	1,8000	1,6953	9,2469
f_4	*b*	**–0,0000**	**–0,0000**	–0,4542	–0,5345	**–0,0000**	**–0,0000**
	μ	**–0,0000**	**–0,0000**	–1,9359	–1,8618	**–0,0000**	**–0,0000**
	σ	**0,0000**	**0,0000**	0,8995	0,7326	**0,0000**	**0,0000**
	t	2,0557	2,8334	3,4531	**1,8935**	1,9363	11,4460
f_5	*b*	**–0,0000**	**–0,0000**	–0,0963	–1,0135	**–0,0000**	**–0,0000**
	μ	**–0,0000**	**–0,0000**	–0,2661	–1,8263	–2,0425	**–0,0000**
	σ	**0,0000**	**0,0000**	0,1022	0,2977	1,5758	**0,0000**
	t	1,9763	2,3081	3,2543	1,8593	**1,5433**	11,1831
f_6	*b*	–8,1623	–12,6205	–1,2911	–20,5466	**–0,0001**	–4,0504
	μ	–9,5894	–13,5730	–34,7168	–40,1160	–13,4663	**–5,5870**
	σ	0,6247	**0,2436**	31,3215	16,8383	19,3225	0,4551
	t	1,5460	2,1079	2,9366	1,5761	**1,3441**	10,8624
f_7	*b*	**–0,0000**	**–0,0000**	–2,2521	–11,6636	**–0,0000**	**–0,0000**
	μ	**–0,0000**	**–0,0000**	–18,9701	–25,7285	**–0,0000**	**–0,0000**
	σ	**0,0000**	**0,0000**	9,5315	5,6655	0,0001	**0,0000**
	t	1,5125	1,9908	2,9382	1,4502	**1,1750**	9,5762
f_8	*b*	586,4596	583,7315	**587,4893**	506,9896	587,4925	587,3307
	μ	551,6431	568,5495	**587,4815**	449,3692	561,7637	582,9138
	σ	18,2414	9,4117	**0,0045**	19,9428	13,7614	4,5609
	t	1,6572	2,3986	2,9414	1,4589	**1,3982**	10,8529

Таблица 4

Результаты непараметрического статистического теста Уилкоксона, выполняемого на основе тестовых функций размерности *n* = 2
[Results of the nonparametric Wilcoxon statistical test performed on the basis of test functions of dimension *n* = 2]

Функция [Function]	QIGA		GA		DE		PSO		NRO	
	Знак [Sign]	p-value	Знак [Sign]	p-value	Знак [Sign]	p-value	Знак [Sign]	p-value	Знак [Sign]	p-value
f_1	+	0,0001	+	0,0000	+	0,0003	+	0,0000	+	0,0001
f_2	+	0,0031	+	0,0000	+	0,0000	+	0,0000	+	0,0007
f_3	+	0,0000	+	0,0000	+	0,0000	+	0,0000	+	0,0003
f_4	+	0,0003	+	0,0000	+	0,0011	+	0,0009	+	0,0003
f_5	+	0,0001	+	0,0000	+	0,0000	+	0,0002	+	0,0014
f_6	+	0,0000	+	0,0000	+	0,0025	+	0,0001	+	0,0001
f_7	+	0,0029	+	0,0000	+	0,0020	+	0,0003	+	0,0008
f_8	+	0,0097	–	0,0000	+	0,0053	+	0,0028	+	0,0055

Таблица 5

Результаты непараметрического статистического теста Уилкоксона, выполняемого на основе тестовых функций размерности *n* = 15
[Results of the nonparametric Wilcoxon statistical test performed on the basis of test functions of dimension *n* = 15]

Функция [Function]	QIGA		GA		DE		PSO		NRO	
	Знак [Sign]	p-value	Знак [Sign]	p-value	Знак [Sign]	p-value	Знак [Sign]	p-value	Знак [Sign]	p-value
f_1	+	0,0073	+	0,0000	+	0,0000	+	0,0000	+	0,0004
f_2	+	0,0096	+	0,0000	+	0,0000	+	0,0006	+	0,0018
f_3	–	0,0001	+	0,0000	+	0,0000	+	0,0000	–	0,0001
f_4	=	0,0540	+	0,0000	+	0,0000	+	0,0029	=	0,0626
f_5	+	0,0107	+	0,0000	+	0,0000	+	0,0000	+	0,0077
f_6	+	0,0085	+	0,0063	+	0,0044	+	0,0090	–	0,0089
f_7	=	0,1464	+	0,0008	+	0,0000	+	0,0071	+	0,0052
f_8	–	0,0035	–	0,0017	+	0,0000	–	0,0152	–	0,0020

По среднему времени выполнения *t* алгоритм MQIGA выигрывает лишь в трех случаях из восьми (функции f_2, f_4, f_7). Наименьшее время выполнения *t* для функций f_1, f_3 показывает алгоритм DE, для функций f_5, f_6, f_8 – алгоритм PSO. При этом необходимо отметить, что на оптимизацию функций f_1 – f_8 алгоритм MQIGA затрачивает наименьшее время *t* в сравнении с его аналогами QIGA и GA.

Выполнение алгоритмов оптимизации на тестовых функциях размерности *n* = 15 (см. табл. 3) демонстрирует, что значения показателей *b*, μ, σ одинаково достигают глобального максимума для функций f_1, f_5, f_7 алгоритмами MQIGA, QIGA, NRO, для функций f_2, f_4 – алгоритмами MQIGA, QIGA, PSO, NRO, для функции f_3 – алгоритмами QIGA, NRO, для функции f_8 – алгоритмом GA. Относительно среднего времени выполнения *t* MQIGA опережает остальные алгоритмы при оптимизации функций f_1, f_2, f_3. Функция f_4 выполняется с наименьшим значением показателя *t* при оптимизации алгоритмом DE, а функции f_5, f_6, f_7, f_8 – при оптимизации алгоритмом PSO. Также стоит отметить, что по аналогии с тестированием двумерных функций (см. табл. 2), для функций f_1 – f_8 размерности *n* = 15 оптимизация модифицированным алгоритмом MQIGA осуществляется быстрее, по сравнению с временем *t*, затрачиваемым на выполнение оптимизации данных функций алгоритмами QIGA и GA.

Результаты непараметрического статистического теста Уилкоксона, выполняемого на основе тестовых функций размерности $n = 2$ (см. табл. 4), демонстрируют превосходство алгоритма MQIGA над всеми другими алгоритмами, за исключением случая с алгоритмом GA для функции f_8. При выполнении непараметрического статистического теста Уилкоксона на основе тестовых функций размерности $n = 15$ (см. табл. 5) алгоритм MQIGA показывает худшие результаты на функциях f_3, f_8 в сравнении с алгоритмом QIGA, на функции f_8 – в сравнении с алгоритмами GA, PSO, на функциях f_3, f_6, f_8 – в сравнении с алгоритмом NRO. В остальных случаях алгоритм MQIGA либо не отличается по качеству получаемых результатов от других алгоритмов, либо превосходит их.

С целью определения скорости достижения глобального максимума оптимизационными алгоритмами используется визуальный подход на основе построения линейных графиков сходимости для функций размерности $n = 2$ (рис. 2, 3) и размерности $n = 15$ (рис. 4, 5).

В соответствии с графиками на рис. 2 и 3 во всех случаях кривая алгоритма MQIGA располагается выше, чем кривые других оптимизационных алгоритмов, что указывает на превосходство алгоритма MQIGA в скорости достижения целевого значения глобального максимума тестовых функций f_1–f_8 размерности $n = 2$.

На графиках, показанных на рис. 4, в большинстве случаев наблюдается достижение кривой алгоритма MQIGA целевого значения глобального максимума тестовых функций f_1–f_4 в интервале с 0 по 50 итерацию. При этом данная кривая располагается выше по сравнению с кривыми других оптимизационных алгоритмов. Однако имеется исключение, которое можно заметить на рис. 4, *a*. Здесь в интервале с 0 по 50 итерацию в отличие от других кривых прослеживается ускоренное приближение кривой алгоритма GA к глобальному максимуму функции f_1, однако далее наблюдается ее значительное замедление и целевое значение глобального максимума достигается на интервале с 150 по 200 итерацию. Вместе с тем кривая алгоритма MQIGA при оптимизации функции f_1 достигает целевого значения глобального максимума примерно на 70 итерации.

На графиках, показанных на рис. 5, при оптимизации многомерных функций f_5 – f_7 кривая алгоритма MQIGA также располагается выше кривых других алгоритмов, что характеризует более высокую скорость ее сходимости. Исключением здесь является рис. 5, *d*, где график демонстрирует значительное превосходство по скорости сходимости алгоритмов GA и PSO над алгоритмом MQIGA. Данный факт может быть связан, например, с необходимостью более «тонкой» настройки гиперпараметров алгоритма MQIGA для оптимизации функции f_8.

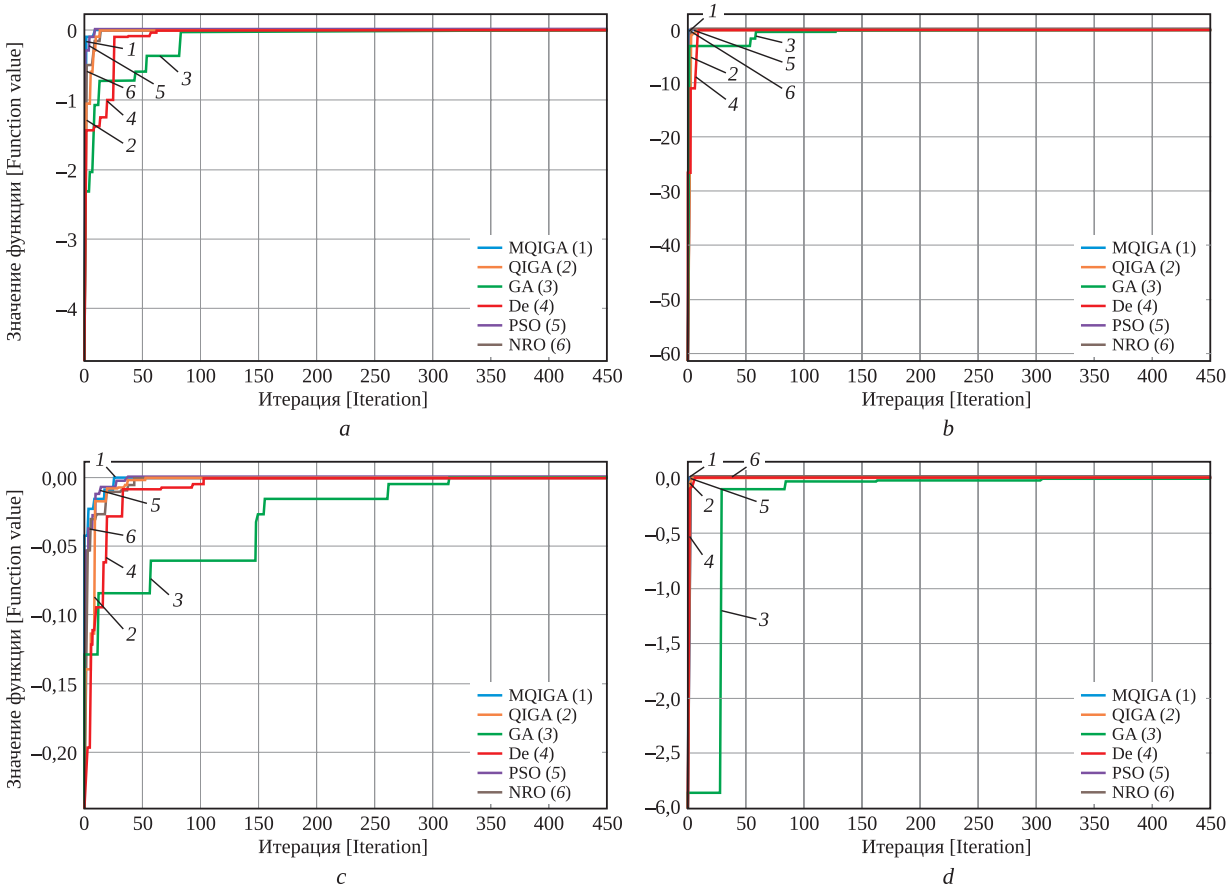

Рис. 2. Графики сходимости для тестовых функций размерности $n = 2$: *a* – f_1; *b* – f_2; *c* – f_3; *d* – f_4

Fig. 2. Convergence graphs for test functions of dimension $n = 2$: *a* – f_1; *b* – f_2; *c* – f_3; *d* – f_4

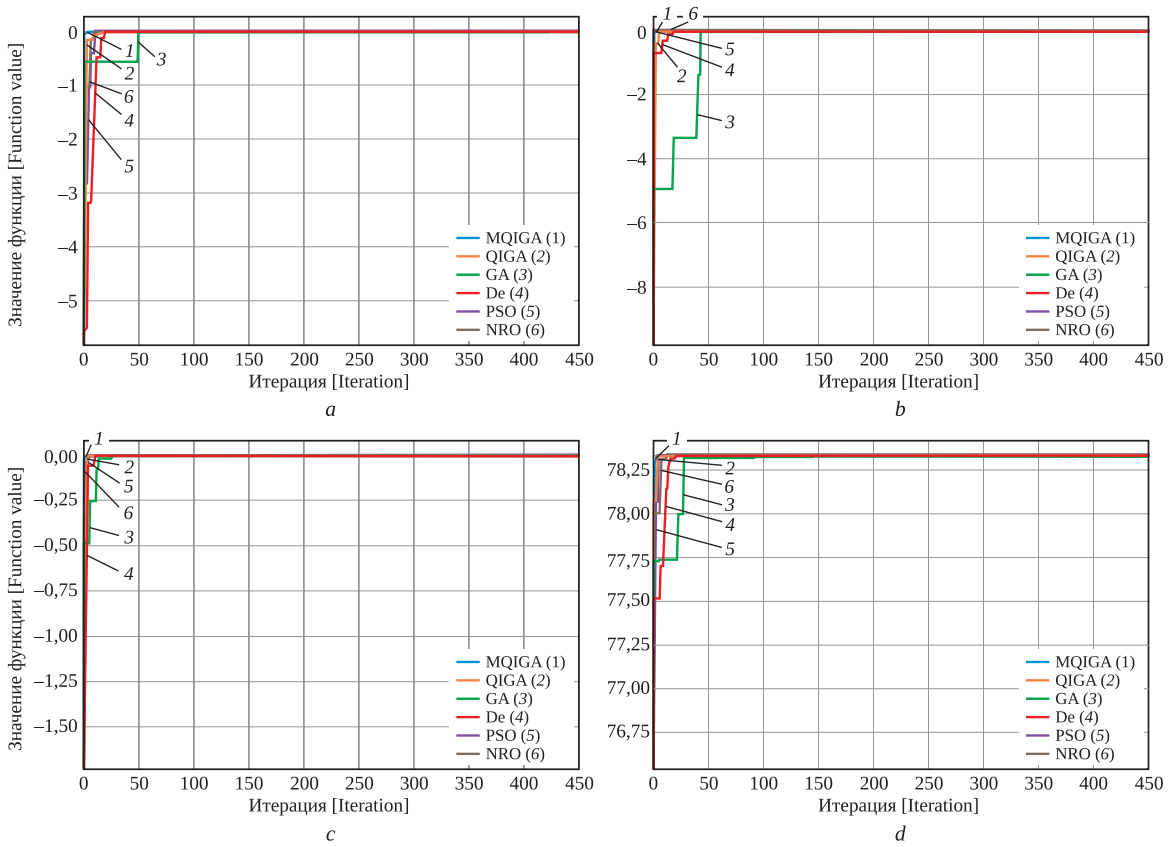

Рис. 3. Графики сходимости для тестовых функций размерности $n = 2$: $a - f_5$; $b - f_6$; $c - f_7$; $d - f_8$

Fig. 3. Convergence graphs for test functions of dimension $n = 2$: $a - f_5$; $b - f_6$; $c - f_7$; $d - f_8$

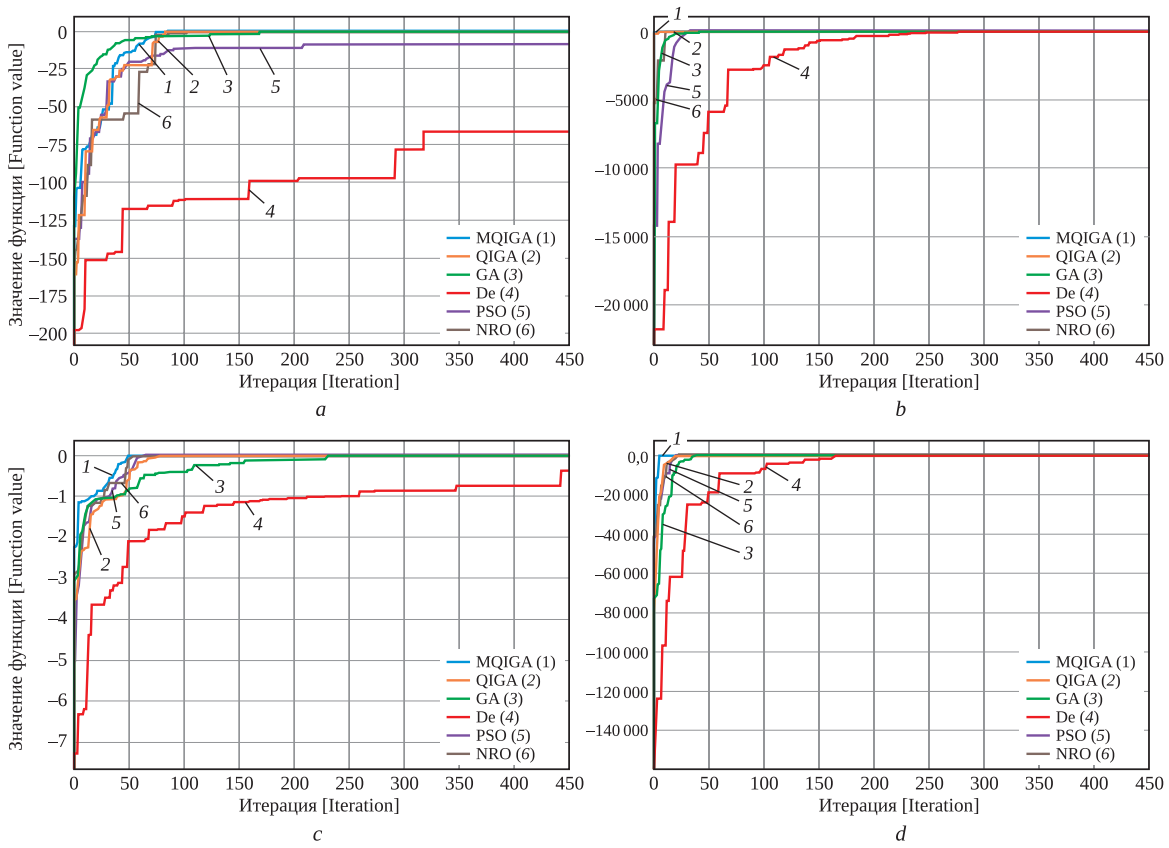

Рис. 4. Графики сходимости для тестовых функций размерности $n = 15$: $a - f_1$; $b - f_2$; $c - f_3$; $d - f_4$

Fig. 4. Convergence graphs for test functions of dimension $n = 15$: $a - f_1$; $b - f_2$; $c - f_3$; $d - f_4$

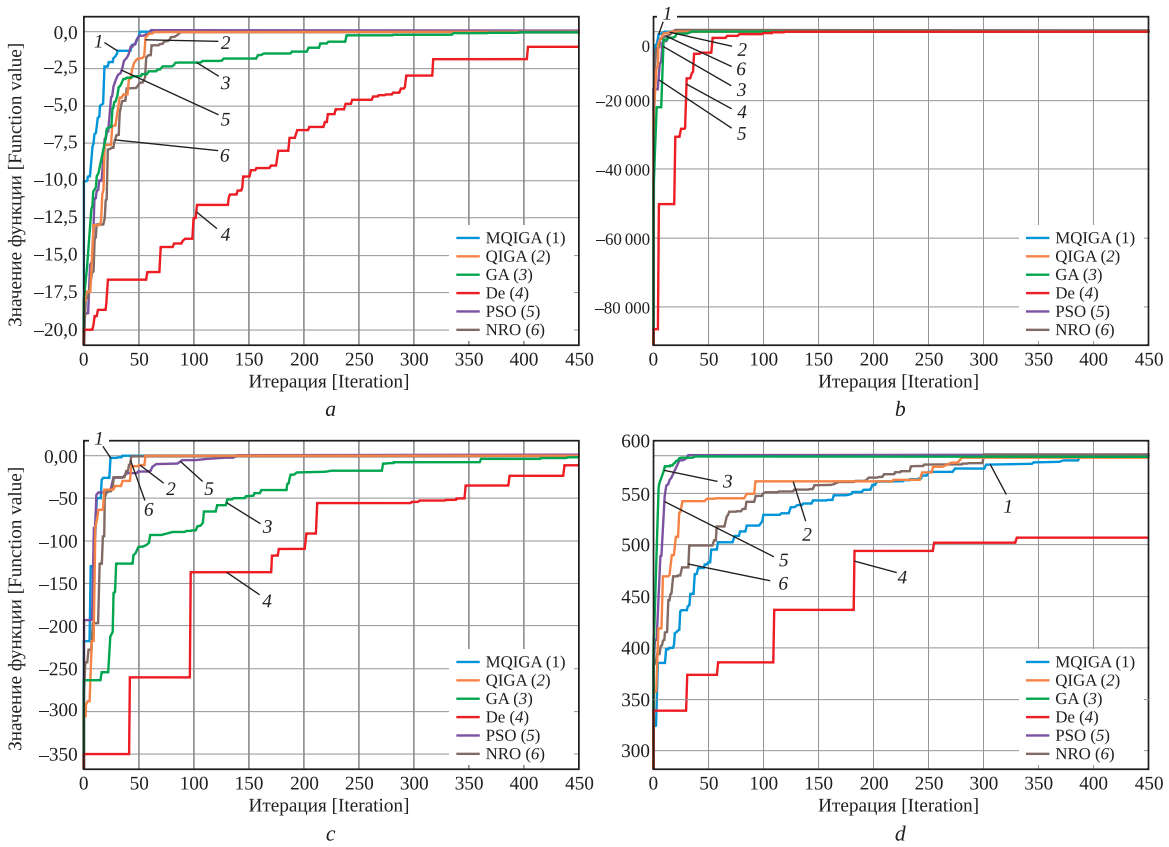

Рис. 5. Графики сходимости для тестовых функций размерности n = 15: a – f_5; b – f_6; c – f_7; d – f_8

Fig. 5. Convergence graphs for test functions of dimension n = 15: a – f_5; b – f_6; c – f_7; d – f_8

Для проверки качества работы MQIGA на практике рассматривается прикладная задача оптимизации планирования гибридного поточного производства в обрабатывающей промышленности на основе финансовых затрат [6]. Математическая модель задачи представляет собой комбинированную функцию, которая формируется из четырех составных функций затрат.

1. Затраты на рабочую силу C_L – это заработная плата сотрудникам промышленного предприятия за выполнение конкретной рабочей деятельности в течение определенного периода времени. Предполагается, что значение C_L является постоянным с учетом ставки почасовой оплаты труда и общего времени работы всех станков. Функция C_L выражается формулой:

$$C_L = \left(\sum_{j=1}^{J} \sum_{s=1}^{S} \sum_{m=1}^{M} t_{jsm} \alpha_{jsm} \right) \left(\frac{h}{60} \right), \qquad (19)$$

где J – общее количество рабочих задач;

S – количество этапов выполнения работ;

M – количество станков;

t_{jsm} – время выполнения работы j на станке m в течение этапа s, мин;

h – ставка почасовой оплаты труда.

При этом коэффициент α_{jsm} равняется единице в случае выполнения работы j на станке m в течение этапа s и равняется нулю в ином случае.

2. Затраты на электроэнергию C_E – это стоимость электроэнергии, которая затрачивается на функционирование станков без учета режимов ожидания или простоя. Функция C_E имеет вид:

$$C_E = \left(\sum_{j=1}^{J} \sum_{s=1}^{S} \sum_{m=1}^{M} t_{jsm} p_{sm} \alpha_{jsm} \right) \left(\frac{l}{60000} \right), \qquad (20)$$

где p_{sm} – номинальная мощность станка;

l – средний тариф на электроэнергию.

3. Затраты на техническое обслуживание C_R – это стоимость выполнения профилактических работ по поддержке станков в рабочем состоянии. Здесь техническое обслуживание осуществляется в соответствии с заданной максимальной продолжительностью работы станков. Функция C_R представляется как:

$$C_R = \sum_{s=1}^{S} \sum_{m=1}^{M} \left(\left\lceil \frac{T_{sm}}{tr_{sm}} \right\rceil r_{sm} \right), \qquad (21)$$

где T_{sm} – общее время работы станка m в течение этапа s;

tr_{sm} – максимальная продолжительность работы станка m на этапе s;

r_{sm} – стоимость выполнения технического обслуживания станка m на этапе s.

4. Штраф за просрочку платежа C_P налагается в связи с невыполнением заказов в согласованные сроки. Данный штраф применяется в том случае, если

производитель не сможет выполнить требуемое количество в установленный временной срок. Функция C_P определяется формулой:

$$C_P = \sum_{j=1}^{J} Y_j, \quad (22)$$

где Y_j – коэффициент опоздания, состоящий из C_j – даты завершения работы,

$$Y_j = \frac{C_j}{w} - D_j,$$

D_j – установленного срока выполнения работы;

w – рабочего времени в день, мин.

При этом коэффициент $Y_j = y_j$ при $y_j > 0$ ($y_j \in Y_j$) и $Y_j = 0$ в ином случае.

Тогда целевая функция финансовых затрат принимает вид:

$$f(\bar{x}) = C_L + C_E + C_R + C_P, \quad (23)$$

где $\bar{x} \in \{N\}$, N – значения, соответствующие параметрам гипотетических сценариев из набора контрольных задач для оценки качества планирования поточного производства [10].

Таким образом, в контексте определения значений параметров гипотетических сценариев, при которых финансовые затраты гибридного поточного производства в обрабатывающей промышленности будут достигать наибольшего значения, возникает задача поиска глобального максимума целевой функции, то есть $f(\bar{x}) \to \max$.

Согласно [10] в табл. 6 приведены значения параметров тестовых сценариев трех выбранных контрольных задач.

В соответствии с [10] для проведения тестирования на основе (23) и гипотетических сценариев (табл. 6) используются квантово-инспирированные оптимизационные алгоритмы MQIGA, QIGA, классические оптимизационные алгоритмы GA, PSO, а также дополнительный алгоритм непрерывной оптимизации методом колонии муравьев (Ant Colony Optimization Continuous, ACOR), отличающийся от исходного алгоритма ACO, применяемого в [10], приращением компонентов вектора варьируемых параметров способом замены дискретного распределения вероятностей функцией плотности вероятностей. Размер популяции в вычислительном эксперименте для всех алгоритмов устанавливается равным 50, максимальное значение итераций – 1000. Оптимизация для каждой контрольной задачи повторяется 10 раз. Результаты тестирования представлены в табл. 7.

Таблица 6

Значения параметров тестовых сценариев выбранных контрольных задач [Parameter values for test scenarios of selected control tasks]

Контрольная задача [Test task]	Количество работ [Number of works]	Количество этапов [Number of stages]	Конфигурации станков [Machine configurations]
J10c5a2	10	5	2 2 1 2 2
J10c5b1	10	5	1 2 2 2 2
J10c5c1	10	5	3 3 2 3 3

Таблица 7

Результаты выполнения алгоритмов оптимизации на основе тестовых сценариев выбранных контрольных задач [Results of execution of optimization algorithms based on test scenarios of selected control problems]

Контрольная задача [Test task]	Показатель [Indicator]	MQIGA	QIGA	GA	PSO	ACOR
J10c5a2	*b*	1234,2600	1233,9747	1231,2381	**1589,2163**	908,6921
	μ	**1218,9135**	1206,0869	1189,7119	1103,5880	882,7458
	σ	31,1418	55,5403	107,0042	274,6011	**13,8010**
	t	**3,9148**	4,0806	4,6541	88,1333	4,1000
J10c5b1	*b*	**1175,8808**	1175,2794	1174,9001	1091,5175	937,5177
	μ	**1133,0001**	1130,9934	1103,5528	799,1208	729,2004
	σ	76,5595	82,3011	130,1895	177,8176	**73,8790**
	t	5,5391	5,3004	5,9426	99,2492	**3,9648**
J10c5c1	*b*	**472,4012**	470,7862	470,9350	455,4077	446,6079
	μ	460,3774	**468,1157**	466,1426	448,1920	442,3017
	σ	9,8622	**2,3052**	3,7721	3,9436	2,4436
	t	7,1088	7,4102	7,8370	119,0849	**5,1289**

По результатам выполнения алгоритмов оптимизации с использованием параметров тестовых сценариев выбранных контрольных задач видно, что модифицированный алгоритм MQIGA в соответствии со значениями показателя b наиболее приближенно достигает целевое значение глобального максимума в случае с решением контрольных задач J10c5b1 и J10c5c1. Лучшее значение времени выполнения t достигается алгоритмом при решении задачи J10c5a2.

Следующим этапом проверки качества работы MQIGA на практике является использование модифицированного алгоритма для повышения точности прогнозирования на основе компактных машин экстремального обучения (Extreme Learning Machine, ELM). Первоначально задача повышения точности прогнозирования на основе компактных ELM с применением алгоритмов глобальной оптимизации поставлена и решена в исследовании [35]. Авторы исследования разработали подходы к интеллектуальной настройке входных весовых коэффициентов в ELM биоинспирированными алгоритмами, что позволило увеличить точность прогнозирования на основе ELM при решении задач восстановления регрессии.

ELM представляет собой алгоритм машинного обучения с учителем, который выполняет принятие решений за счет автоматического конфигурирования сложной нелинейной системы для определенной задачи. Структура ELM подразумевает искусственную нейронную сеть прямого распространения, содержащую один скрытый слой с бесконечно дифференцируемой функцией активации. При этом весовые коэффициенты между нейронами входного и скрытого слоев, а также смещения скрытого слоя инициализируются случайным образом, а весовые коэффициенты между нейронами скрытого и выходного слоев, наоборот, вычисляются. Однако случайная инициализация весовых коэффициентов между нейронами входного и скрытого слоев и случайная инициализация смещений скрытого слоя не всегда обеспечивает получение наилучшей конфигурации ELM [30].

Обобщающая способность обученной модели искусственной нейронной сети часто оценивается при помощи функции средней абсолютной ошибки (Mean Absolute Error, MAE), рассчитываемой как:

$$\mathrm{MAE} = \frac{1}{n}\sum_{i=1}^{n}\left|y_i - f\left(x_i\right)\right|, \qquad (24)$$

где n – количество объектов в наборе данных для обучения;

x_i – i-й объект из набора данных для обучения;

$f(x_i)$ – результат прогнозирования на основе ELM для объекта x_i;

y_i – истинный результат для объекта x_i.

С целью исследования эффективности алгоритма MQIGA в решении задачи настройки входных весовых коэффициентов и смещений скрытого слоя в ELM рассматриваются 3 набора данных из открытых источников, которые описываются в статьях [18; 21]:

- первый набор данных CPU Performance содержит информацию о производительности центральных процессоров (10 столбцов, 209 объектов);
- второй набор данных Auto Imports содержит информацию о ценах на автомобили (26 столбцов, 206 объектов);
- третий набор данных Boston Housing содержит информацию о ценах на дома в Бостоне (14 столбцов, 506 объектов).

Для восстановления регрессионной зависимости для перечисленных наборов данных используются как модель компактной классической реализации ELM [35], так и модели ELM на основе метаэвристических оптимизационных алгоритмов из табл. 2 с интеллектуальной настройкой весовых коэффициентов и смещений. Размер популяции для всех оптимизационных алгоритмов устанавливается равным 100, а максимальное значение итераций – 300. При этом рассматриваемые алгоритмы имеют следующие настройки специфицированных параметров.

1. MQIGA: длина квантовой хромосомы – 4, длина кудита – 5, уровень ошибки – 0,01, частота мутации – 0,01, вероятность мутации – 0,05.
2. QIGA: длина квантовой хромосомы – 4, частота мутации – 0,01, вероятность мутации – 0,05.
3. GA: вероятность скрещивания – 0,9, вероятность мутации – 0,1.
4. DE: весовой коэффициент – 0,7, частота скрещивания – 0,9.
5. PSO: локальный коэффициент – 0,8, глобальный коэффициент – 0,5.
6. NRO: дополнительные параметры отсутствуют.

В табл. 8 представлены средние значения MAE (24) на тестовых подмножествах рассматриваемых наборов данных, полученные применением метода перекрестной проверки по 10 блокам к моделям ELM, MQIGA-ELM, QIGA-ELM, GA-ELM, DE-ELM, PSO-ELM, NRO-ELM.

Исходя из результатов, представленных в табл. 8, видно, что наилучшая обобщающая способность среди рассмотренных моделей наблюдается у модели MQIGA-ELM. При этом модели QIGA-ELM, GA-ELM, PSO-ELM, NRO-ELM с проведенной интеллектуальной настройкой весовых коэффициентов и смещений показывают лучшую обобщающую способность на всех наборах данных в сравнении с моделью компактной классической реализации ELM с одинаковым количеством нейронов на скрытом слое [35].

Полученные в ходе тестирования наблюдения свидетельствуют о том, что для двумерных тестовых функций MQIGA достигает глобальный максимум в 100% экспериментов с опережением всех других алгоритмов по времени выполнения в 38% экспериментов.

Таблица 8

Средние значения MAE на тестовых подмножествах рассматриваемых наборов данных, полученные применением метода перекрестной проверки по 10 блокам к набору ELM-моделей [Average MAE values on test subsets of the considered datasets, obtained by applying the 10-block cross-validation method to a set of ELM models]

Набор данных [Dataset]	ELM	MQIGA-ELM	QIGA-ELM	GA-ELM	DE-ELM	PSO-ELM	NRO-ELM
CPU Performance	12,9	**5,3**	7,8	9,1	13,6	8,0	6,6
Auto Imports	2604	**2080**	2145	2148	2452	2176	2119
Boston Housing	3,35	**1,86**	2,42	2,64	3,49	2,77	2,53

Для многомерных тестовых функций размерности n = 15 MQIGA достигает глобальный максимум в 75% экспериментов. При этом модифицированный алгоритм выполняется быстрее остальных алгоритмов в 37,5% экспериментов, а по скорости сходимости в экспериментах с многомерными функциями MQIGA выигрывает в 87,5% экспериментов.

При решении прикладной оптимизационной задачи планирования гибридного поточного производства алгоритм MQIGA достигает глобальный максимум в 67% экспериментов. Относительно времени выполнения MQIGA опережает все другие алгоритмы в 33% экспериментов.

В задаче повышения точности прогнозирования на основе компактных машин экстремального обучения модель ELM, дополненная алгоритмом MQIGA, выполняет прогнозирование с наилучшим значением показателя MAE во всех выполненных экспериментах.

Следует отметить, что значения показателей качества работы модифицированного алгоритма MQIGA могут варьироваться в зависимости от корректности настройки гиперпараметров для решения поставленной оптимизационной задачи, от сложности поверхности целевой функции оптимизационной задачи, а также от аппаратных характеристик вычислительного устройства, на котором выполняется оптимизация, вследствие чего значение найденного глобального максимума, время выполнения алгоритма, скорость сходимости с глобальным максимумом и показатель средней абсолютной ошибки в проведенных экспериментах могут меняться как в отрицательную, так и в положительную сторону.

ЗАКЛЮЧЕНИЕ

В ходе исследования, рассмотренного в данной статье, предложен новый модифицированный генетический алгоритм численной оптимизации MQIGA, основанный на квантово-инспирированном моделировании с использованием кудита в условиях имитации квантовой декогеренции. Для его реализации представлен аналог сферы Блоха для кудитов в виде матрицы плотности на базе применения операторов Гейзенберга–Вейля, позволяющий осуществлять квантовые операции вращения состояний многоуровневых квантовых систем. Имитация квантовой декогеренции рассматривается с точки зрения влияния стороннего шума окружающей среды на кудит и характеризуется дополнительным использованием в квантовых вентилях нормальной случайной величины с нулевым математическим ожиданием и единичной дисперсией. Также в работе представлен общий псевдокод алгоритма, включая псевдокоды составляющих его элементов и операций, таких как вычисление квантовых и классических хромосом, инициализация генов квантовой популяции, оценка функции приспособленности, вычисление обновленных квантовых хромосом, операции скрещивания и мутации.

Проверка качества модифицированного алгоритма MQIGA на тестовых двумерных и многомерных функциях, а также при решении прикладной оптимизационной задачи планирования гибридного поточного производства в обрабатывающей промышленности на основе финансовых затрат и решении задачи повышения точности прогнозирования на основе компактных машин экстремального обучения демонстрирует превосходство нового алгоритма по времени выполнения, скорости сходимости и точности решения над обычным квантово-инспирированным алгоритмом QIGA и представленными классическими оптимизационными алгоритмами. Этот факт также подтверждается результатами исследования [37], в котором говорится о невозможности достижения классическими оптимизационными алгоритмами преимуществ квантово-инспирированных алгоритмов, вследствие чего допускается сделать утверждение о целесообразности использования алгоритма MQIGA для решения практических задач однокритериальной оптимизации в различных прикладных областях. Однако, как показывают вычислительные эксперименты, получение удовлетворительных значений показателей качества MQIGA во многом зависит от правильного подбора значений параметров в соответствии со сложностью

поверхности целевой функции решаемой оптимизационной задачи, включая размер квантовой популяции, длину квантовой хромосомы, максимальное число итераций, длину кудита, уровень ошибки, вызванной влиянием шума на кудит, частоту и вероятность мутации.

В перспективе дальнейших исследований предлагается добавление возможности поиска глобального минимума оптимизируемых функций, повышение уровня устойчивости сходимости с глобальным оптимумом, поиск способов нивелирования застреваний в локальных минимумах многомерных функций со сложными поверхностями, реализация специализированного автоматизированного метода настройки гиперпараметров алгоритмов машинного обучения [12], а также разработка метода многокритериальной оптимизации на базе свойств и математических особенностей функционирования текущего алгоритма MQIGA.

Литература

1. *Arute F., Arya K., Babbush R.* et al. Quantum supremacy using a programmable superconducting processor // Nature. 2019. No. 574. Pp. 505–510. DOI: 10.1038/s41586-019-1666-5
2. *Arrazola J., Delgado A., Bardhan B., Lloyd S.* Quantum-inspired algorithms in practice // Quantum. 2020. No. 4. P. 307. DOI: 10.22331/q-2020-08-13-307
3. *Abs da Cruz A.V., Vellasco M.M.B.R., Pacheco M.A.C.* Quantum-inspired evolutionary algorithm for numerical optimization // *IEEE International Conference on Evolutionary Computation*. 2006. Pp. 2630–2637. DOI: 10.1109/CEC.2006.1688637
4. *Asadian A., Erker P., Huber M., Klöckl C.* Heisenberg–Weyl observables: Bloch vectors in phase space // Physical Review A. 2016. No. 94. DOI: 10.1103/PhysRevA.94.010301
5. *Aksenov M., Zalivako I., Semerikov I.* et al. Realizing quantum gates with optically addressable Yb + 171 ion qudits // Physical Review A. 2023. No. 107. DOI: 10.1103/PhysRevA.107.052612
6. *Ab Rashid M.F.F., Mu'tasim M.A.N.* Modeling and optimization of cost-based hybrid flow shop scheduling problem using metaheuristics // International Journal of Global Optimization and Its Application. 2023. No. 2. Pp. 244–254. DOI: 10.56225/ijgoia.v2i4.265
7. *Beiranvand V., Hare W., Lucet Y.* Best practices for comparing optimization algorithms // Optimization and Engineering. 2017. No. 18. DOI: 10.1007/s11081-017-9366-1
8. *Chen J., Zhang F., Chen M.* et al. Classical simulation of intermediate-size quantum circuits. 2018. DOI: 10.48550/arXiv.1805.01450.
9. *Chabaud U., Ferrini G., Grosshans F., Markham D.* Classical simulation of Gaussian quantum circuits with non-Gaussian input states // Physical Review Research. 2021. No. 3. DOI: 10.1103/PhysRevResearch.3.033018
10. *Carlier J., Néron E.* An exact method for solving the multi-processor flow-shop // RAIRO – Operations Research. 2000. No. 34. Pp. 1–25. DOI: 10.1051/ro:2000103
11. *Demidova L., Gorchakov A.* A study of chaotic maps producing symmetric distributions in the fish school search optimization algorithm with exponential step decay // Symmetry. 2020. No. 12. P. 784. DOI: 10.3390/sym12050784
12. *Demidova L., Nikulchev E., Sokolova Y.* The SVM classifier based on the modified particle swarm optimization // International Journal of Advanced Computer Science and Applications. 2016. No. 7. Pp. 16–24. DOI: 10.14569/IJACSA.2016.070203
13. *Fay M., Proschan M.* Wilcoxon–Mann–Whitney or t-test? On assumptions for hypothesis test and multiple interpretations of decision rules // Statistics Surveys. 2010. No. 4. Pp. 1–39. DOI: 10.1214/09-SS051

References

1. *Arute F., Arya K., Babbush R.* et al. Quantum supremacy using a programmable superconducting processor. *Nature*. 2019. No. 574. Pp. 505–510. DOI: 10.1038/s41586-019-1666-5
2. *Arrazola J., Delgado A., Bardhan B., Lloyd S.* Quantum-inspired algorithms in practice. *Quantum*. 2020. No. 4. P. 307. DOI: 10.22331/q-2020-08-13-307
3. *Abs da Cruz A.V., Vellasco M.M.B.R., Pacheco M.A.C.* Quantum-inspired evolutionary algorithm for numerical optimization. *IEEE International Conference on Evolutionary Computation*. 2006. Pp. 2630–2637. DOI: 10.1109/CEC.2006.1688637
4. *Asadian A., Erker P., Huber M., Klöckl C.* Heisenberg–Weyl observables: Bloch vectors in phase space. *Physical Review A*. 2016. No. 94. DOI: 10.1103/PhysRevA.94.010301
5. *Aksenov M., Zalivako I., Semerikov I. et* al. Realizing quantum gates with optically addressable Yb + 171 ion qudits. *Physical Review A*. 2023. No. 107. DOI: 10.1103/PhysRevA.107.052612
6. *Ab Rashid M.F.F., Mutasim M.A.N.* Modeling and optimization of cost-based hybrid flow shop scheduling problem using metaheuristics. *International Journal of Global Optimization and Its Application*. 2023. No. 2. Pp. 244–254. DOI: 10.56225/ijgoia.v2i4.265
7. *Beiranvand V., Hare W., Lucet Y.* Best practices for comparing optimization algorithms. *Optimization and Engineering*. 2017. No. 18. DOI: 10.1007/s11081-017-9366-1
8. *Chen J., Zhang F., Chen M.* et al. Classical simulation of intermediate-size quantum circuits. 2018. DOI: 10.48550/arXiv.1805.01450.
9. *Chabaud U., Ferrini G., Grosshans F., Markham D.* Classical simulation of Gaussian quantum circuits with non-Gaussian input states. *Physical Review Research*. 2021. No. 3. DOI: 10.1103/PhysRevResearch.3.033018
10. *Carlier J., Néron E.* An exact method for solving the multi-processor flow-shop. *RAIRO – Operations Research*. 2000. No. 34. Pp. 1–25. DOI: 10.1051/ro:2000103
11. *Demidova L., Gorchakov A.* A study of chaotic maps producing symmetric distributions in the fish school search optimization algorithm with exponential step decay. *Symmetry*. 2020. No. 12. P. 784. DOI: 10.3390/sym12050784
12. *Demidova L., Nikulchev E., Sokolova Y.* The SVM classifier based on the modified particle swarm optimization. *International Journal of Advanced Computer Science and Applications*. 2016. No. 7. Pp. 16–24. DOI: 10.14569/IJACSA.2016.070203
13. *Fay M., Proschan M.* Wilcoxon–Mann–Whitney or t-test? On assumptions for hypothesis test and multiple interpretations of decision rules. *Statistics Surveys*. 2010. No. 4. Pp. 1–39. DOI: 10.1214/09-SS051

14. *Huang Q.*, *Mendl C.* Classical simulation of quantum circuits using a multiqubit Bloch vector representation of density matrices // Physical Review A. 2022. No. 105. DOI: 10.1103/PhysRevA.105.022409
15. *Hao T.*, *Huang X.*, *Jia C.*, *Peng C.* A quantum-inspired tensor network algorithm for constrained combinatorial optimization problems // Frontiers in Physics. 2022. No. 10. P. 906590. DOI: 10.3389/fphy.2022.906590
16. *Han K.*, *Kim J.* Genetic quantum algorithm and its application to combinatorial optimization problem // Proceedings of the IEEE Conference on Evolutionary Computation, ICEC. 2000. Vol. 2. Pp. 1354–1360. DOI: 10.1109/CEC.2000.870809
17. *Hakemi S.*, *Houshmand M.*, *KheirKhah E.*, *Hosseini S.* A review of recent advances in quantum-inspired metaheuristics // Evolutionary Intelligence. 2022. No. 1-16. DOI: 10.1007/s12065-022-00783-2
18. *Harrison D.*, *Rubinfeld D.* Hedonic housing prices and the demand for clean air // Journal of Environmental Economics and Management. 1978. No. 5. Pp. 81–102. DOI: 10.1016/0095-0696(78)90006-2
19. *Kaul D.*, *Raju H.*, *Tripathy B.K.* Quantum-computing-inspired algorithms in machine learning. 2018. DOI: 10.4018/978-1-5225-5219-2.ch001
20. *Krysenko D.*, *Prudnikov O.* Laser cooling of 171Yb+ ion in polychromatic light field // Journal of Experimental and Theoretical Physics. 2023. No. 137. Pp. 239–245. DOI: 10.1134/S1063776123080149
21. *Kibler D.*, *Aha D.W.*, *Albert M.K.* Instance-based prediction of real-valued attributes // Computational Intelligence. 1989. No. 5 (2). Pp. 51–57. DOI: 10.1111/j.1467-8640.1989.tb00315.x
22. *Moretti V.* Mathematical foundations of quantum mechanics: An advanced short course // International Journal of Geometric Methods in Modern Physics. 2015. No. 13. DOI: 10.1142/S0219887816300117
23. *Nowotniak R.*, *Kucharski J.* Building Blocks propagation in quantum-inspired genetic algorithm // Scientific Bulletin of Academy of Science and Technology, Automatics. 2010. No. 14.
24. *Preskill J.* Quantum computing in the NISQ era and beyond // Quantum. 2018. No. 2. DOI: 10.22331/q-2018-08-06-79
25. *Sabbar B.M.*, *Rasool H.A.* Quantum inspired genetic algorithm model based automatic modulation classification // Webology. 2021. Vol. 18. Special Issue. Pp. 1070–1085. DOI: 10.14704/WEB/V18SI04/WEB18182. EDN: BNCEZA.
26. *Schlosshauer M.* Decoherence, the measurement problem, and interpretations of quantum mechanics // Reviews of Modern Physics. 2003. No. 76. Pp. 1267–1305.
27. *Schlosshauer M.* Quantum decoherence // Physics Reports. 2019. Vol. 831. Pp. 1–57. DOI: 10.1016/j.physrep.2019.10.001. EDN PTXNOQ
28. *Sharma G.*, *Ghosh S.* Four-dimensional Bloch sphere representation of qutrits using Heisenberg–Weyl operators. 2021. URL: https://arxiv.org/abs/2101.06408
29. *Sofge D.* Prospective algorithms for quantum evolutionary computation: Proceedings of the Second Quantum Interaction Symposium (QI-2008). College Publications, UK, 2008. URL: https://arxiv.org/pdf/0804.1133
30. *Song S.J.*, *Wang Y.*, *Lin X.*, *Huang Q.* Study on GA-based training algorithm for extreme learning machine: 7th International Conference on Intelligent Human-Machine Systems and Cybernetics (IHMSC). Hangzhou, China, 2015. Pp. 132–135. DOI: 10.1109/IHMSC.2015.156.

14. *Huang Q.*, *Mendl C.* Classical simulation of quantum circuits using a multiqubit Bloch vector representation of density matrices. *Physical Review A.* 2022. No. 105. DOI: 10.1103/PhysRevA.105.022409
15. *Hao T.*, *Huang X.*, *Jia C.*, *Peng C.* A quantum-inspired tensor network algorithm for constrained combinatorial optimization problems. *Frontiers in Physics*. 2022. No. 10. P. 906590. DOI: 10.3389/fphy.2022.906590
16. *Han K.*, *Kim J.* Genetic quantum algorithm and its application to combinatorial optimization problem. *Proceedings of the IEEE Conference on Evolutionary Computation, ICEC*. 2000. Vol. 2. Pp. 1354–1360. DOI: 10.1109/CEC.2000.870809
17. *Hakemi S.*, *Houshmand M.*, *KheirKhah E.*, *Hosseini S.* A review of recent advances in quantum-inspired metaheuristics. *Evolutionary Intelligence*. 2022. No. 1-16. DOI: 10.1007/s12065-022-00783-2
18. *Harrison D.*, *Rubinfeld D.* Hedonic housing prices and the demand for clean air. *Journal of Environmental Economics and Management*. 1978. No. 5. Pp. 81–102. DOI: 10.1016/0095-0696(78)90006-2
19. *Kaul D.*, *Raju H.*, *Tripathy B.K.* Quantum-computing-inspired algorithms in machine learning. 2018. DOI: 10.4018/978-1-5225-5219-2.ch001
20. *Krysenko D.*, *Prudnikov O.* Laser cooling of 171Yb+ ion in polychromatic light field. *Journal of Experimental and Theoretical Physics*. 2023. No. 137. Pp. 239–245. DOI: 10.1134/S1063776123080149
21. *Kibler D.*, *Aha D.W.*, *Albert M.K.* Instance-based prediction of real-valued attributes. *Computational Intelligence*. 1989. No. 5 (2). Pp. 51–57. DOI: 10.1111/j.1467-8640.1989.tb00315.x
22. *Moretti V.* Mathematical foundations of quantum mechanics: An advanced short course. *International Journal of Geometric Methods in Modern Physics*. 2015. No. 13. DOI: 10.1142/S0219887816300117
23. *Nowotniak R.*, *Kucharski J.* Building Blocks propagation in quantum-inspired genetic algorithm. *Scientific Bulletin of Academy of Science and Technology, Automatics*. 2010. No. 14.
24. *Preskill J.* Quantum computing in the NISQ era and beyond. *Quantum*. 2018. No. 2. DOI: 10.22331/q-2018-08-06-79
25. *Sabbar B.M.*, *Rasool H.A.* Quantum inspired genetic algorithm model based automatic modulation classification // Webology. 2021. Vol. 18. Special Issue. Pp. 1070–1085. DOI: 10.14704/WEB/V18SI04/WEB18182. EDN: BNCEZA.
26. *Schlosshauer M.* Decoherence, the measurement problem, and interpretations of quantum mechanics. *Reviews of Modern Physics.* 2003. No. 76. Pp. 1267–1305.
27. *Schlosshauer M.* Quantum decoherence. *Physics Reports*. 2019. Vol. 831. Pp. 1–57. DOI: 10.1016/j.physrep.2019.10.001. EDN PTXNOQ
28. *Sharma G.*, *Ghosh S.* Four-dimensional Bloch sphere representation of qutrits using Heisenberg–Weyl operators. 2021. URL: https://arxiv.org/abs/2101.06408
29. *Sofge D.* Prospective algorithms for quantum evolutionary computation: Proceedings of the Second Quantum Interaction Symposium (QI-2008). College Publications, UK, 2008. URL: https://arxiv.org/pdf/0804.1133
30. *Song S.J.*, *Wang Y.*, *Lin X.*, *Huang Q.* Study on GA-based training algorithm for extreme learning machine: 7th International Conference on Intelligent Human-Machine Systems and Cybernetics (IHMSC). Hangzhou, China, 2015. Pp. 132–135. DOI: 10.1109/IHMSC.2015.156.

31. *Thieu N.V.*, *Mirjalili S*. MEALPY: An open-source library for latest meta-heuristic algorithms in Python // Journal of Systems Architecture. 2023. No. 139. DOI: 10.1016/j.sysarc.2023.102871
32. *Wang Y.*, *Hu Z.*, *Sanders B.*, *Kais S*. Qudits and High-Dimensional Quantum Computing // Frontiers in Physics. 2020. No. 8. DOI: 10.3389/fphy.2020.589504
33. *Zhang G*. Quantum-inspired evolutionary algorithms: A survey and empirical study // J. Heuristics. 2011. No. 17. Pp. 303–351. DOI: 10.1007/s10732-010-9136-0
34. *Żurek W*. Decoherence, einselection, and the quantum origins of the classical // Reviews of Modern Physics. 2001. No. 75. DOI: 10.1103/RevModPhys.75.715
35. *Демидова Л.А.*, *Горчаков А.В.* Применение биоинспирированных алгоритмов глобальной оптимизации для повышения точности прогнозов компактных машин экстремального обучения // Russian Technological Journal. 2022. Т. 10. № 2. С. 59–74. DOI: 10.32362/2500-316X-2022-10-2-59-74. EDN: WCFZVD.
36. *Корж О.В.*, *Чернявский А.Ю.*, *Корж А.А.* Моделирование квантового преобразования Фурье с шумами на суперкомпьютере Ломоносов // Научный сервис в сети Интернет: все грани параллелизма: труды Междунар. суперкомпьютерной конф., Новороссийск, 23–28 сентября 2013 г. Новороссийск: Изд-во Моск. гос. ун-та, 2013. С. 188–193. EDN: SXFHSD.
37. *Масленников В.В.* Квантово-инспирированные оптимизационные алгоритмы в решении задач оперативного управления // Новые информационные технологии в научных исследованиях: матер. XXVIII Всерос. науч.-техн. конф. студентов, молодых ученых и специалистов, Рязань, 22–24 ноября 2023 г. Рязань: Рязанский гос. радиотехнический ун-т им. В.Ф. Уткина, 2023. С. 42–44. EDN: TTUMEJ.

31. *Thieu N.V.*, *Mirjalili S*. MEALPY: An open-source library for latest meta-heuristic algorithms in Python. *Journal of Systems Architecture*. 2023. No. 139. DOI: 10.1016/j.sysarc.2023.102871
32. *Wang Y.*, *Hu Z.*, *Sanders B.*, *Kais S*. Qudits and High-Dimensional Quantum Computing. *Frontiers in Physics*. 2020. No. 8. DOI: 10.3389/fphy.2020.589504
33. *Zhang G*. Quantum-inspired evolutionary algorithms: A survey and empirical study. *J. Heuristics*. 2011. No. 17. Pp. 303–351. DOI: 10.1007/s10732-010-9136-0
34. *Żurek W*. Decoherence, einselection, and the quantum origins of the classical. *Reviews of Modern Physics*. 2001. No. 75. DOI: 10.1103/RevModPhys.75.715
35. *Demidova L.A.*, *Gorchakov A.V.* Application of bioinspired global optimization algorithms to improve the accuracy of forecasts of compact extreme learning machines. *Russian Technological Journal*. 2022. Vol. 10. No. 2. Pp. 59–74. (In Rus.). DOI: 10.32362/2500-316X-2022-10-2-59-74. EDN: WCFZVD.
36. *Korzh O.V.*, *Chernyavsky A.Yu.*, *Korzh A.A.* Modeling of the quantum Fourier transform with noise on a Lomonosov supercomputer. In: Scientific service on the Internet: All facets of parallelism: Proceedings of the International Supercomputer Conference, Novorossiysk, September 23–28, 2013. Novorossiysk: Publishing House of the Moscow State University, 2013. Pp. 188–193. (In Rus.). EDN: SXFHSD.
37. *Maslennikov V.V.* Quantum-inspired optimization algorithms in solving operational management problems. In: New information technologies in scientific research: Materials of the XXVIII All-Russian Scientific and Technical Conference of Students, Young Scientists and Specialists, Ryazan, November 22–24, 2023. Ryazan: Ryazan State Radio Engineering University named after V.F. Utkin, 2023. Pp. 42–44. (In Rus.). EDN: TTUMEJ.

Статья проверена программой Антиплагиат. Оригинальность – 90,4%

Р е ц е н з е н т: *Андрианова Е.Г.*, кандидат технических наук, доцент; заведующая, кафедра корпоративных информационных систем, Институт информационных технологий; МИРЭА – Российский технологический университет

Статья поступила в редакцию 22.04.2024, принята к публикации 18.05.2024
The article was received on 22.04.2024, accepted for publication 18.05.2024

СВЕДЕНИЯ ОБ АВТОРАХ

Масленников Владимир Владимирович, старший преподаватель, кафедра корпоративных информационных систем, Институт информационных технологий; МИРЭА – Российский технологический университет; г. Москва, Российская Федерация. ORCID ID: 0000-0003-3201-2228; РИНЦ Author ID: 1108283; E-mail: vldmsn@yahoo.com

Демидова Лилия Анатольевна, доктор технических наук, профессор; профессор, кафедра корпоративных информационных систем, Институт информационных технологий; МИРЭА – Российский технологический университет; г. Москва, Российская Федерация. ORCID ID: 0000-0003-4516-3746; Scopus Author ID: 56406258800; РИНЦ Author ID: 499156; E-mail: liliya.demidova@rambler.ru

ABOUT THE AUTHORS

Vladimir V. Maslennikov, senior lecturer, Department of Corporate Information Systems, Institute of Information Technology; MIREA – Russian Technological University; Moscow, Russian Federation. ORCID ID: 0000-0003-3201-2228; RSCI Author ID: 1108283; E-mail: vldmsn@yahoo.com

Liliya A. Demidova, Dr. Sci. (Eng.), Professor; professor, Department of Corporate Information Systems, Institute of Information Technology; MIREA – Russian Technological University; Moscow, Russian Federation. ORCID ID: 0000-0003-4516-3746; Scopus Author ID: 56406258800; RSCI Author ID: 499156; E-mail: liliya.demidova@rambler.ru